예술의 전당 콘서트홀의 예매 데이터 분석을 통한 공연별 · 좌석별 〈적정 가격 예측 모델〉 및 〈예매 취소 예측 모델〉 설계

목차

1. 개요 p. 2
2. 데이터 전처리 p. 3
3. 탐색적 데이터 분석(EDA) p. 13
4. 〈모델링 1〉 콘서트홀 공연별 가격 예측 모델 p. 31
5. 〈모델링 1〉 결과 활용 p. 40
6. 〈모델링 1〉 시사점 p. 41
7. 〈모델링 2〉 콘서트홀 공연별 취소표 예측 모델 p. 42
8. 〈모델링 2〉 결과 활용 p. 50
9. 〈모델링 2〉 시사점 p. 55

개요



엔데믹, 소비자 불만족

엔데믹 이후 큰 규모의 공연을 주축으로
공연 시장이 활황 &
팬데믹 당시 가격 인상에 대한 소비자 불만족



가격예측, 정책 구상

소비자 효용 극대, 많은 예매 촉진 가능한
가격 예측 모델 제작 &
좌석 정보 기반 가격 및 할인 정책 구상



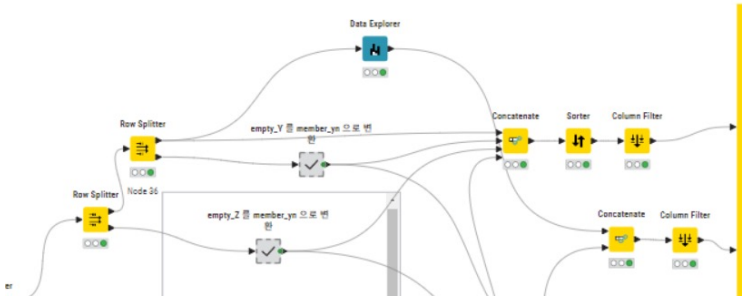
분석 개요

예매취소, 가격 칼럼을 각각 목표변수인
Y1, Y2로 설정하고, 이에 영향을 줄 것으로 예상
되는 변수와의 관계를 바탕으로 모델링

1) 멤버십 여부 열(member_yn)이 뒷 열로 후퇴된 데이터 처리

Y열과 Z열(1696개)

member_yn 특성만 밀려있고, 공연정보 열들 (performance_code, pre_opend_date, open_date, genre, place, running_time, intermission) 은 결측

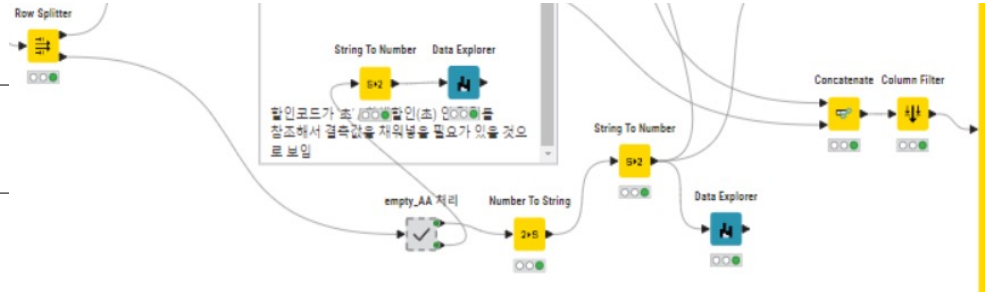


Y열과 Z열("Y"혹은"N")

Y열과 Z열에 있는 데이터로 공백인 member_yn 특성을 채워주는 처리를 진행

AA열 (882개)

member_yn 특성만 AA 열로 밀린 것이 아니라, 모든 공연정보 열들(performance_code ~ intermission) 과 discount_type 열이 한 열씩 뒤로 밀려서 저장됨



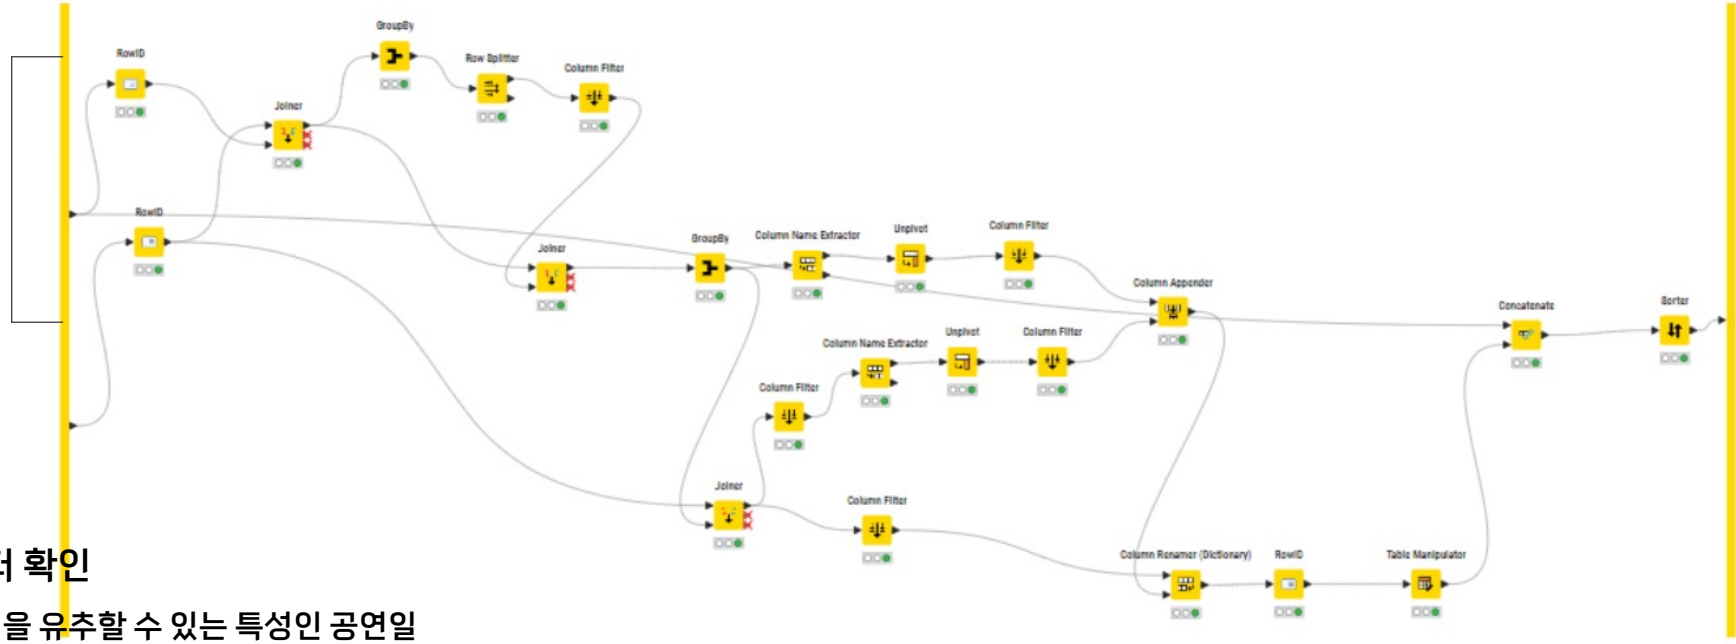
AA열 ("Y"혹은"N")

밀린 모든 열들을 올바른 위치로 당겨오는 처리를 진행함

2) 공연정보 열들 (performance_code ~ intermission) 의 결측치 채우기

데이터 구분

데이터를 공연정보가 누락된 데이터셋 A (1,696개) 과 공연정보가 누락되지 않은 데이터셋 B (1,046,879개) 로 구분



A 데이터 확인

A 에 공연을 유추할 수 있는 특성인 공연일 (play_date), 공연 시작 시간 (play_st_time), 예매가격 (price) 칼럼들은 결측되어 있지 않음을 확인

A와 B비교

A 와 B 를 비교하여, A 에 있는 데이터와 공연일, 공연 시작 시간, 예매가격이 모두 같은 B 데이터들을 찾아서 내부 조인 (Inner Join)

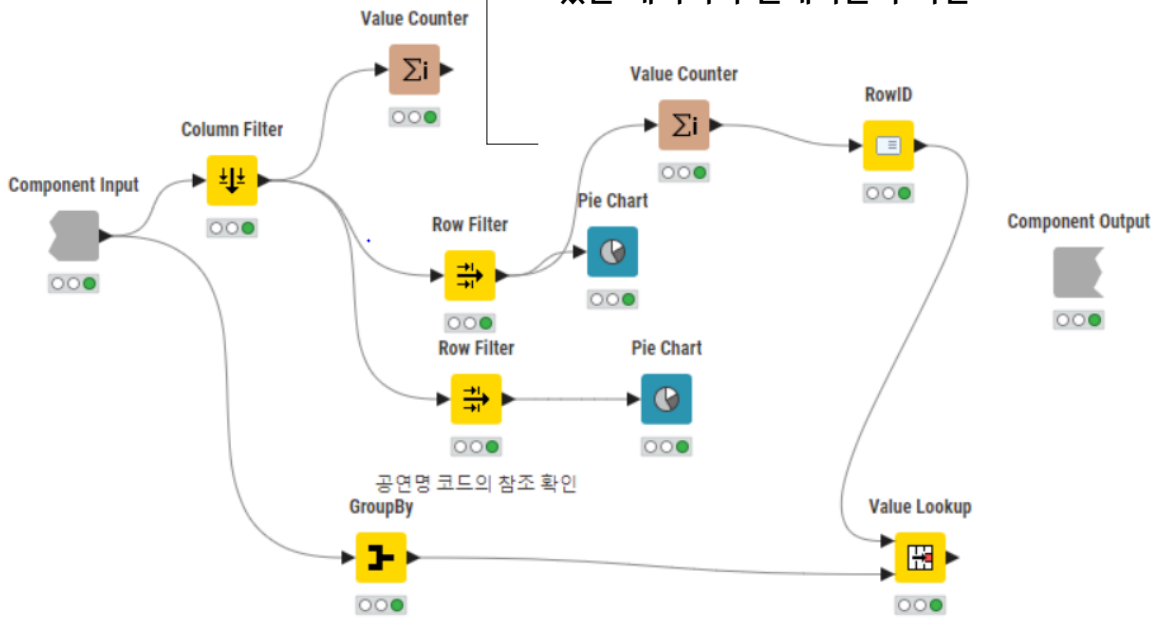
결측치 처리

내부 조인 결과 A 의 개별 행에 대응되는 B 의 여러 행들의 공연명 코드 (performance_code) 가 모두 동일한 경우, A 의 개별 행의 공연정보를 B 의 여러 행들의 공연정보의 최빈값으로 채워넣기

3) 장르 열 (genre) 의 결측치 채우기

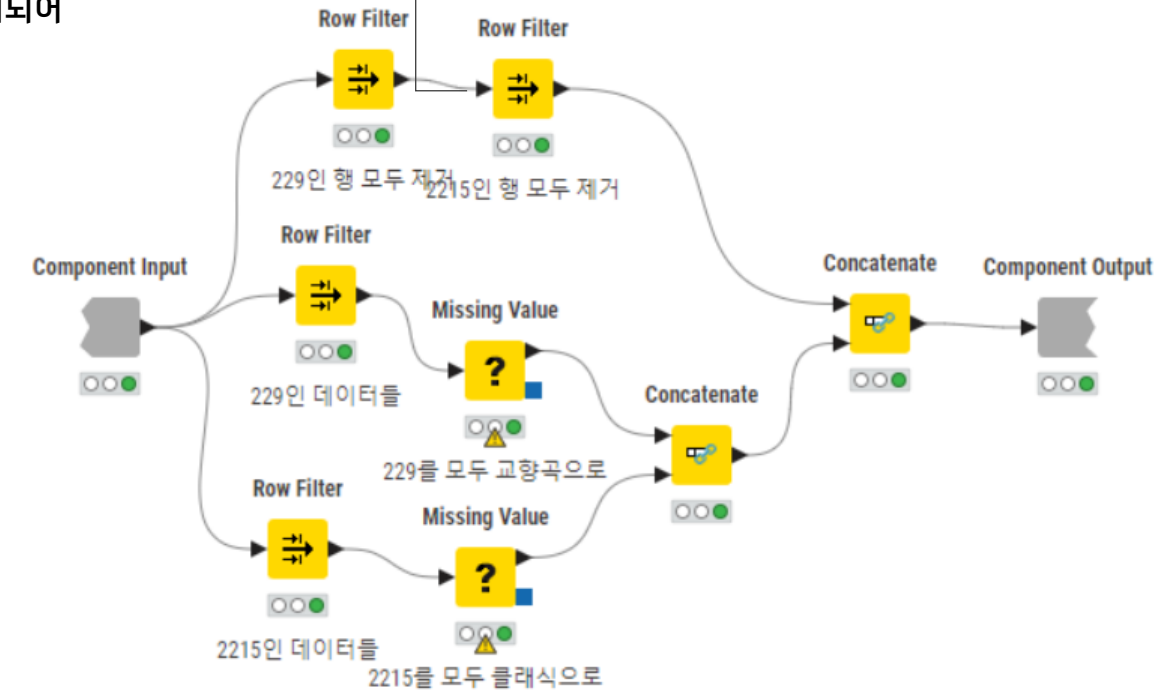
방법1 공연명코드 참조

장르가 결측된 값들에 대해서 공연명 코드 (performance_code) 가 같으면서, 장르가 명시되어 있는 데이터가 존재하는지 확인



방법1 공연명코드 참조

확인 결과, 공연명 코드가 2215인 행들의 장르는 모두 클래식, 229인 행들의 장르는 모두 교향곡
따라서 이 값들로 결측치를 채움.

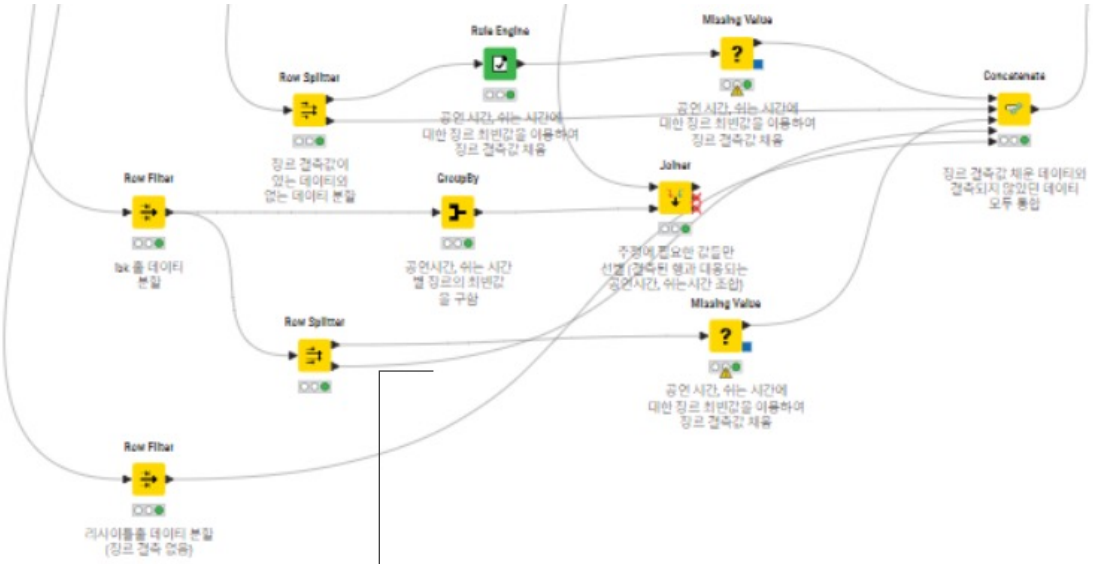


3) 장르 열 (genre) 의 결측치 채우기

방법2 공연 장소, 공연 시간, 쉬는 시간 참조

공연 장소 별로 공연 시간 (running_time), 쉬는 시간 (intermission) 의 조합에 따른 장르의 최빈값을 식별

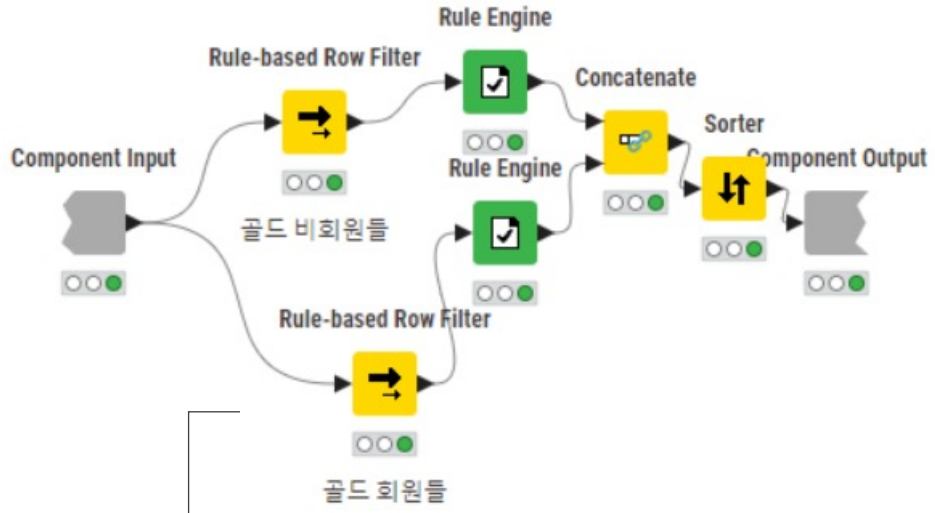




방법2 공연 장소, 공연 시간, 쉬는 시간 참조

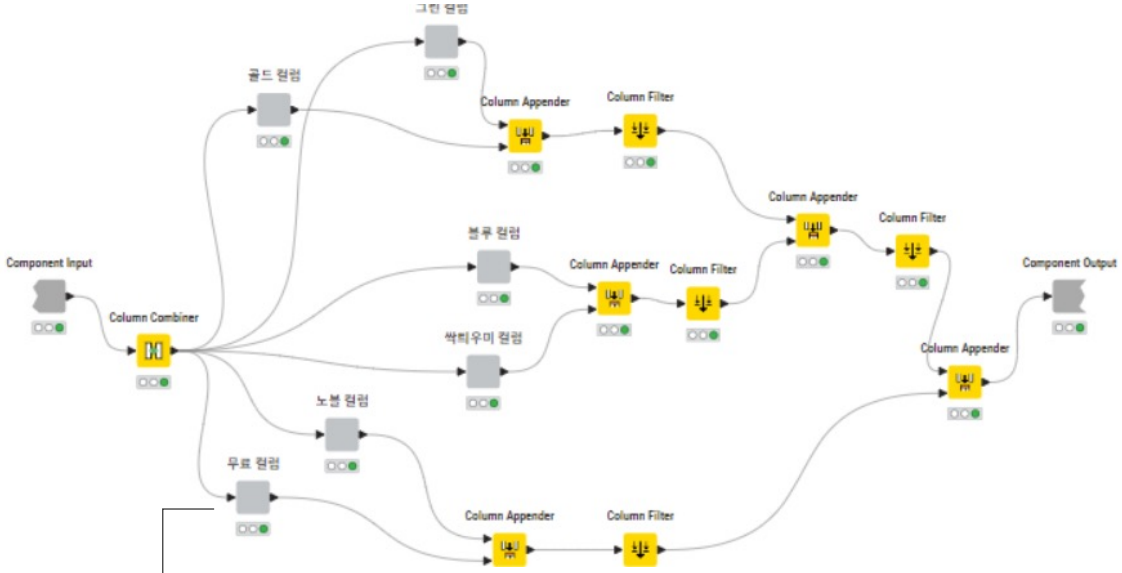
장르가 결측된 데이터들의 공연 장소, 공연 시간, 쉬는 시간 정보를 조합하여 위에서 구한 최빈값으로 결측값을 대체

4) 멤버십 열 (membership-type 1~6) 의 변환



칼럼 생성

membership_type 1 ~ 6 중 단 하나의 행에라도 '골드' 값이 존재하면 1, 모든 행에 '골드' 값이 없으면 0 인 '골드' 칼럼 생성



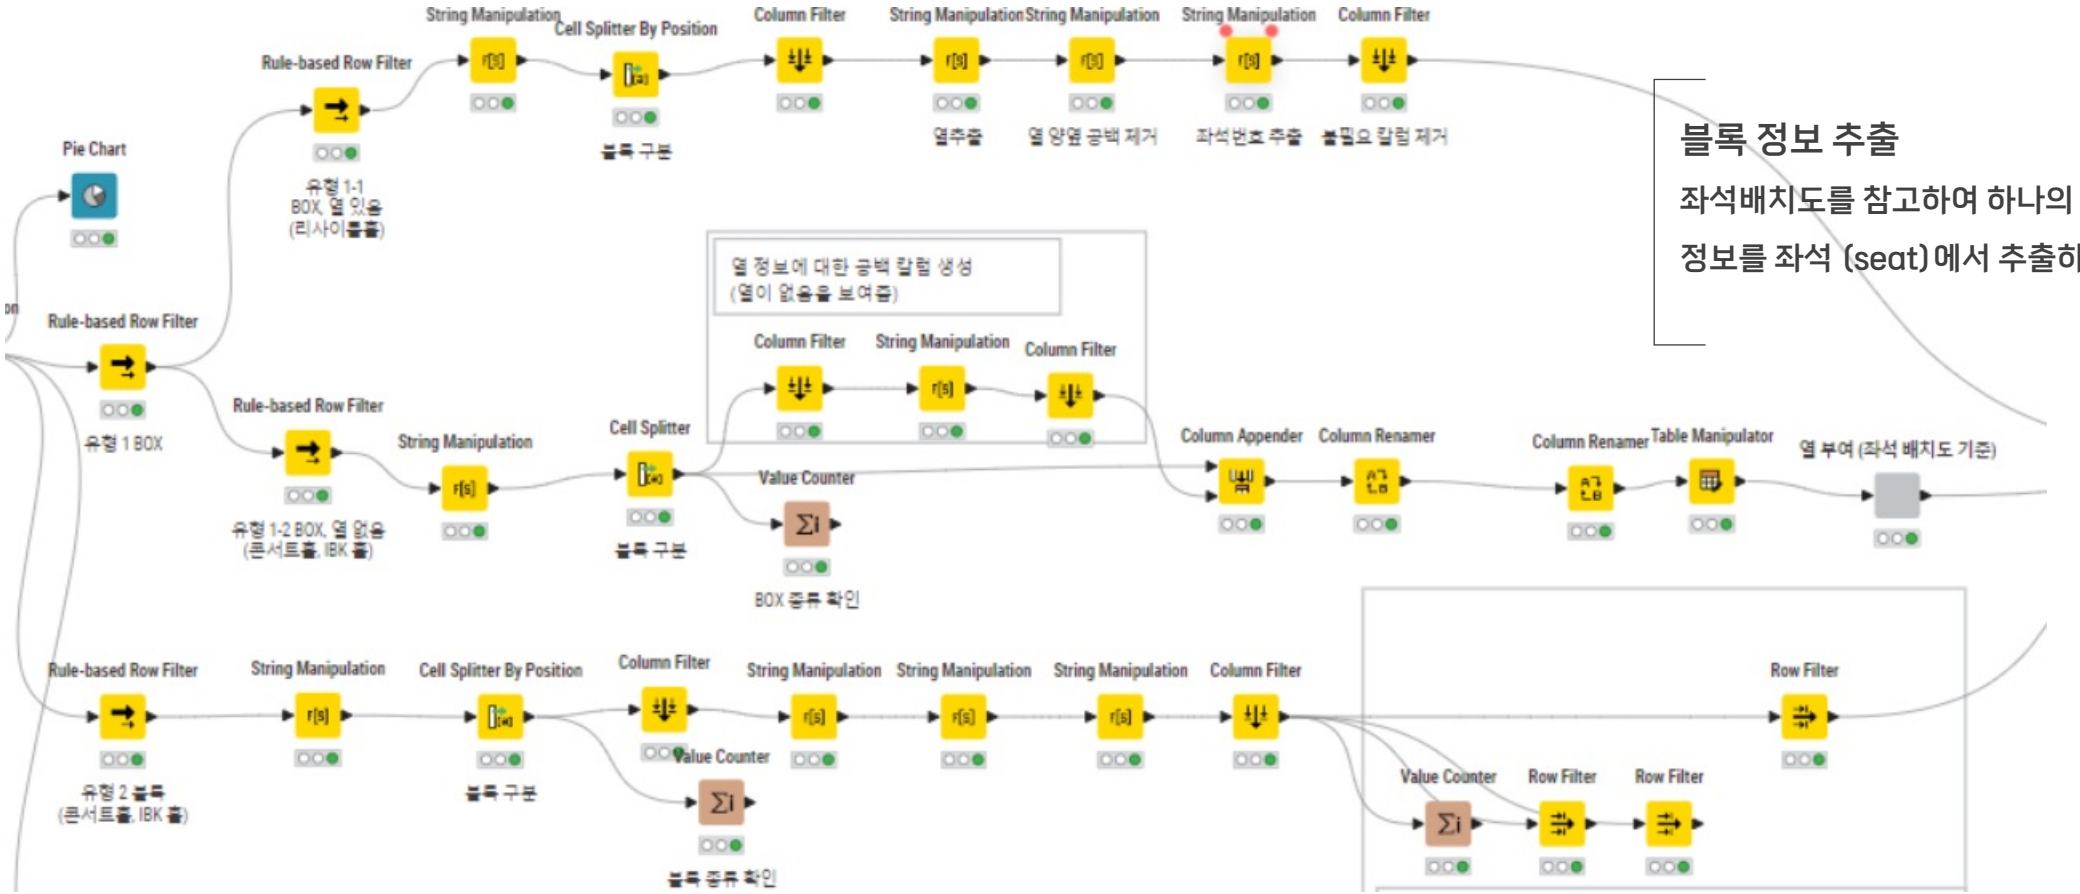
칼럼 생성

왼쪽 과정을 멤버십 타입 6개에 모두 적용

5) 좌석 열 (seat) 의 정보를 추출

층 정보 추출

〈1층, 2층, 3층, 합창석〉 중 하나에 해당하는 정보를 좌석 (seat) 에서 추출하여 "층" 칼럼에 저장함.



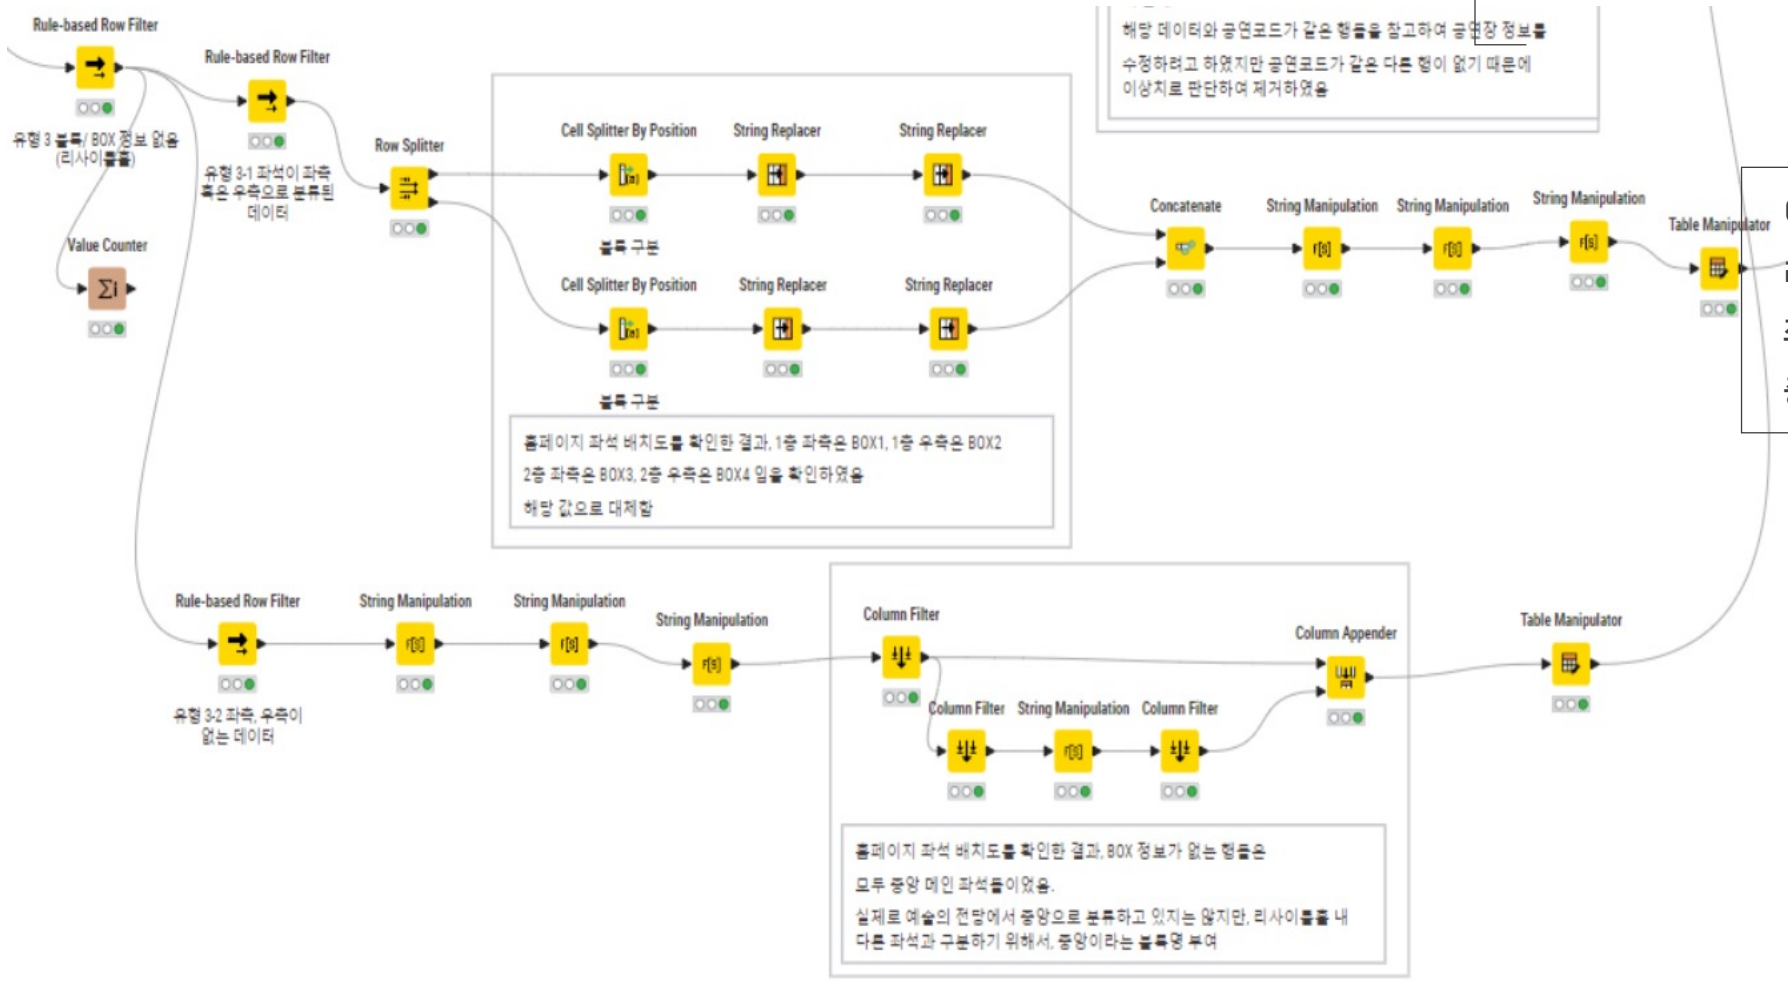
블록 정보 추출

좌석배치도를 참고하여 하나의 층 안에 구분해놓은 블록 정보를 좌석 (seat) 에서 추출하여 "블록"칼럼에 저장함.

5) 좌석 열 (seat) 의 정보를 추출

이상치 처리

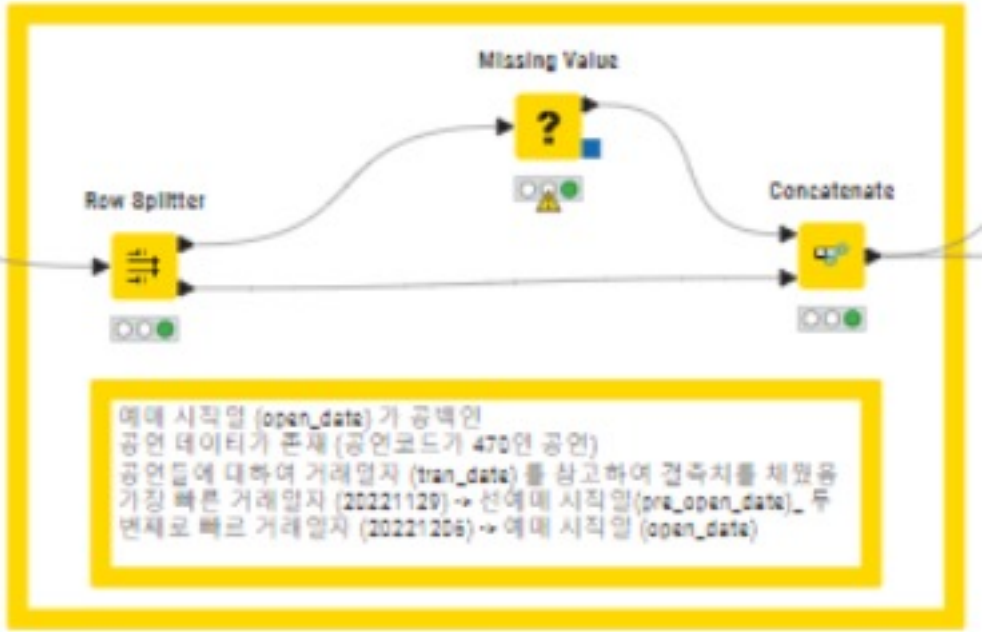
리사이틀홀에서 좌측, 우측으로 표현된 정보를 좌석배치도를 참고하여 BOX로 바꿈 그리고 "블록" 칼럼에 저장



이상치 처리

리사이틀홀에서 좌측, 우측 정보가 모두 없는 경우 좌석배치도를 참고하여 중앙위치임을 확인 후 블록값에 중앙 값을 부여 후 "블록" 칼럼에 저장

6) 선예매시작일 열 (pre_open_date), 예매시작일 열 (open_date) 이상치, 결측치 처리

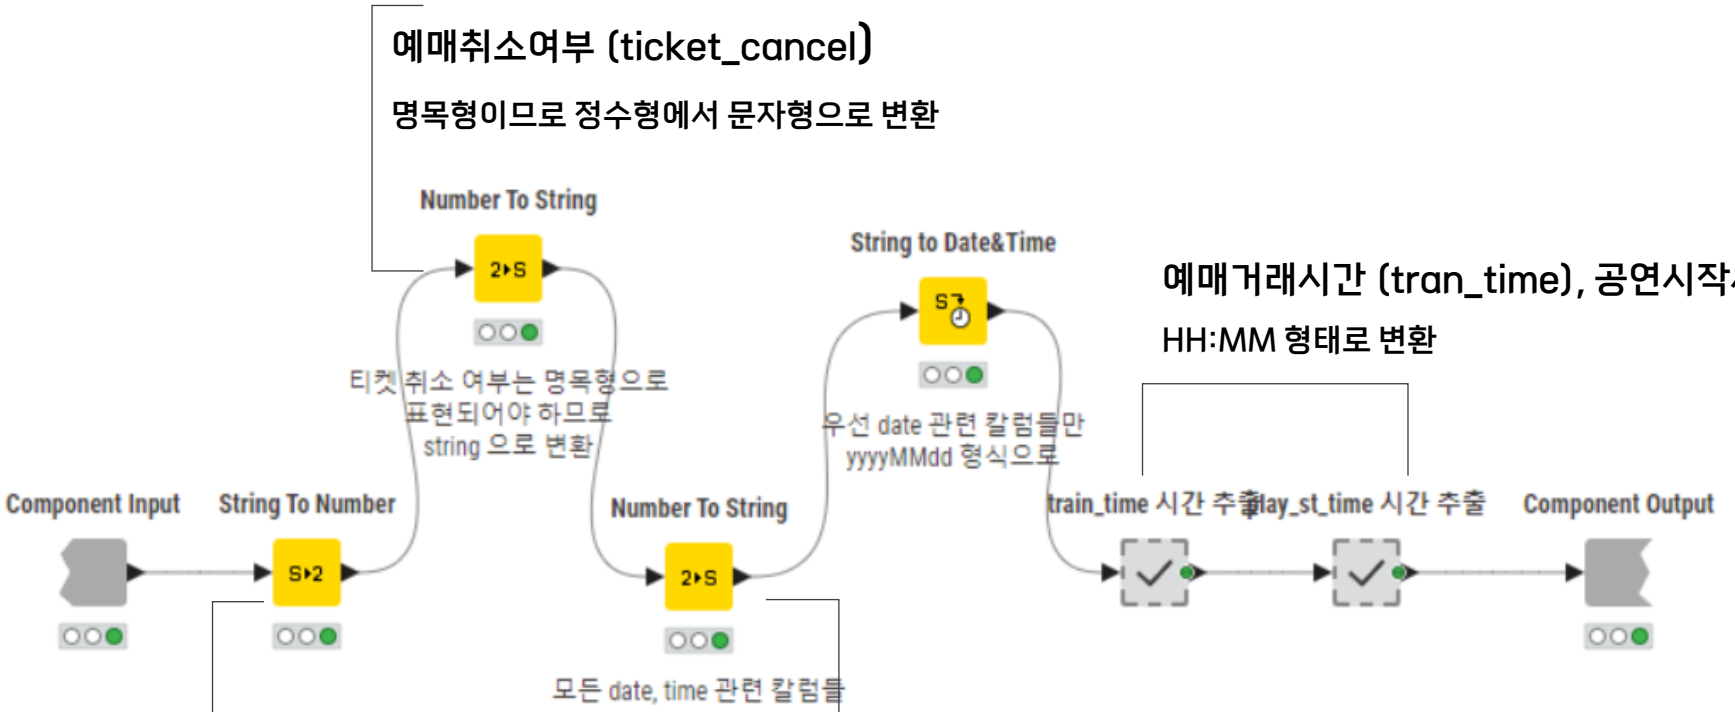


선예매시작일 열 (pre_open_date), 예매시작일 열 (open_date)

공연명 코드가 479인 것 중 예매 거래 일자 (tran_date) 가 가장 빠른 하나의 데이터의 거래 일자 (20221129) 를 선예매 시작일로 설정하고, 그 다음으로 예매 거래 일자가 빠른 날짜 (20221206) 을 예매시작일로 설정함. 두 값을 활용하여 공연명 코드가 479인 모든 공연의 선예매시작일과 예매시작일의 결측값을 채워넣음

7) 컬럼들의 자료형 변환

→특성들의 자료형을 분석과 모델링에 더 적합한 형태로 변환



예매취소여부 (ticket_cancel)

명목형이므로 정수형에서 문자형으로 변환

예매거래시간 (tran_time), 공연시작시간 (play_st_time)

HH:MM 형태로 변환

러닝타임 (running_time)

문자형에서 정수형으로 변환

예매거래일자 (tran_date), 공연날짜 (play_date)

선예매시작일 (pre_open_date), 예매시작일 (open_date)

문자형에서 정수형으로 변환 : yyyymmdd 형태로 변환

탐색적 데이터 분석 EDA

EDA 기본사항

- EDA과정에서 목표변수인 Y1,Y2에 영향을 줄 것이라고 예상되는 변수들과의 관계를 확인
- 그 변수의 분포와 다른 변수들과의 관계도 확인

〈데이터의 칼럼을 변수에 따라 분류한 표〉

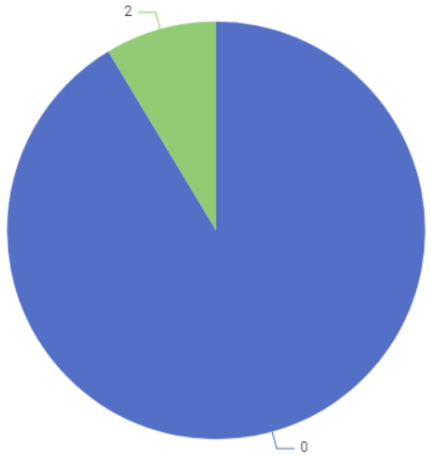
변수명	칼럼명
목표변수 Y1,Y2	Price, ticket_cancel
장르 변수	Performance_code, genre
장소 변수	Place, 층, 블록, 열, 좌석번호
예매 변수	Pre_open_date,open_date
공연 변수	Play_date,play_st_time,intermission,running time
멤버십 변수	싹틔우미, 무료, 노블, 그린, 블루, 골드

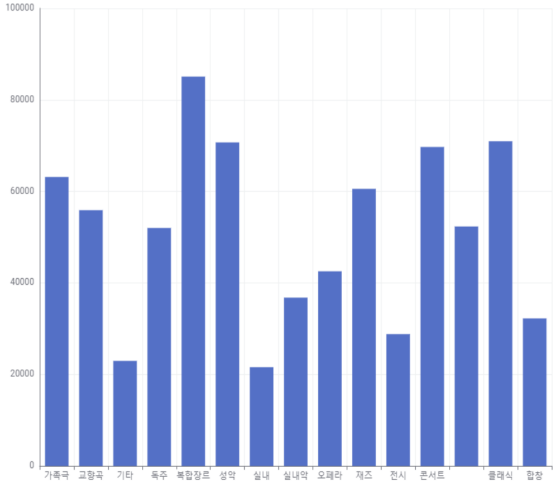
장르와 목표변수 Y1, Y2와의 관계

예매취소와의 관계

다음 파이차트처럼 장르별로 취소의 비율을 시각화함.

복합장르(42%), 교향곡(39%), 성악(38%), 클래식(38%) 등의 순서대로 티켓 취소비율이 높고 나머지 장르들은 35%보다 작았음. 반대로 전시(0%), 기타(9%), 재즈(26%) 등의 순서대로 티켓 취소 비율이 낮았음.





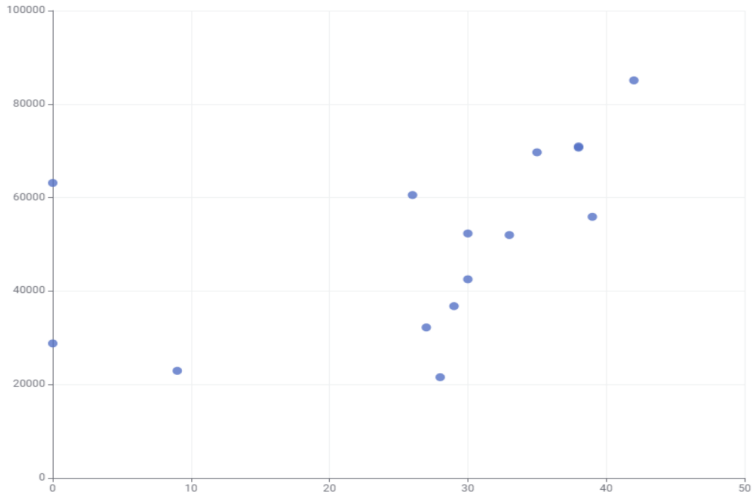
가격과의 관계

다음 막대그래프처럼 장르별로 평균가격을 시각화함.

복합장르, 클래식, 성악, 콘서트 등의 순서대로 평균가격이 높았음.

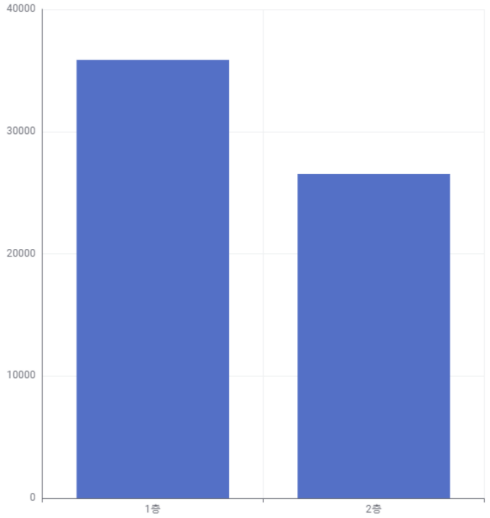
예매취소 비율별 가격과의 관계

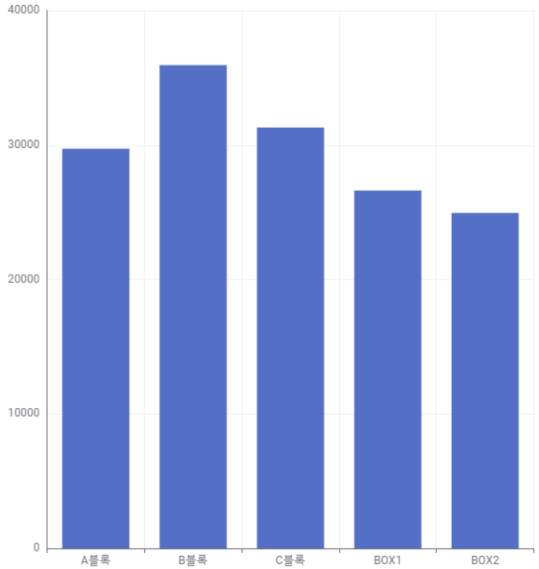
예매취소 비율별 가격에 대한 scatter plot & correlation value를 확인한 결과, 장르의 티켓 평균가격이 높을수록 취소비율이 높아진다는 결론을 얻을 수 있었음



corr = -1 corr = +1 corr = n/a	cancel%	Mean(...
cancel%	1	0.505
Mean(price)	0.505	1

장소의 좌석과 목표변수 Y1, Y2와의 관계 -IBK 챔버홀





기본 사항

- 좌석이 같은 4열 5이어도 장소별,층별,블록별로 모두 다 다른 자리가 됨.
- 따라서 일차적으로 장소별로 데이터를 분할하고 좌석배치도를 참고하여 층별, 블록별로 데이터를 분류함.
- 가격은 평균 가격이며, 그룹화와 막대그래프를 이용하여 차이를 한눈에 볼 수 있게끔 함.

층별 / 블록별 가격비교

층 : 1층 〉 2층

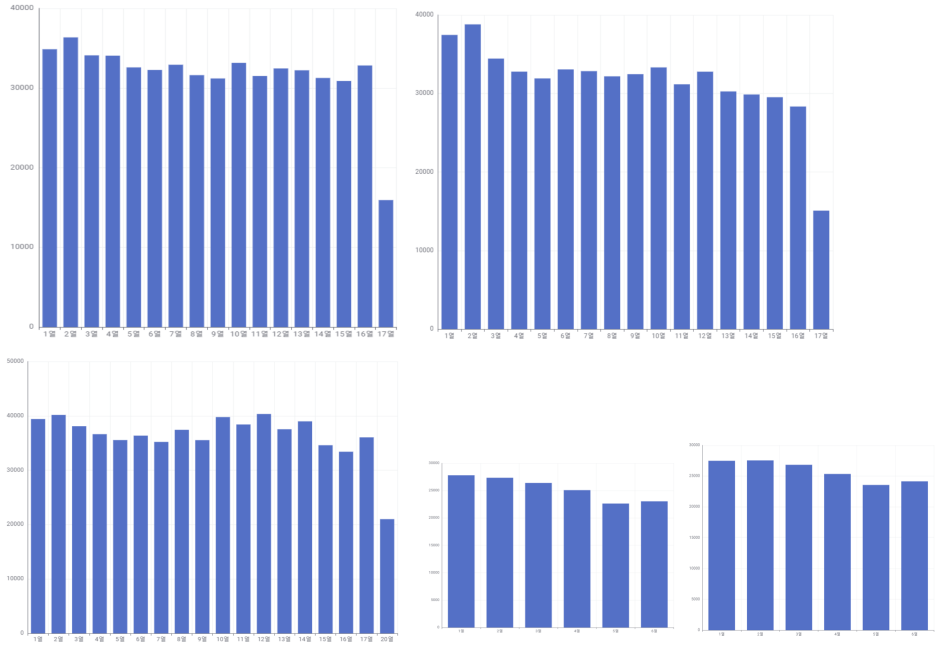
블록 : B 〉 C 〉 A 〉 BOX1 〉 BOX2

관찰 결과

- 중앙에 위치할수록 가격 높고, 좌석배치도를 참고했을 때 A블록은 C블록과 위치관계가 같고 가격대가 비슷하여 하나로 묶을 수 있음
- 동일한 이유로, BOX1도 BOX2와 묶을 수 있음

탐색적 데이터 분석 EDA

장소의 좌석과 목표변수 Y1, Y2와의 관계 -IBK 챔버홀

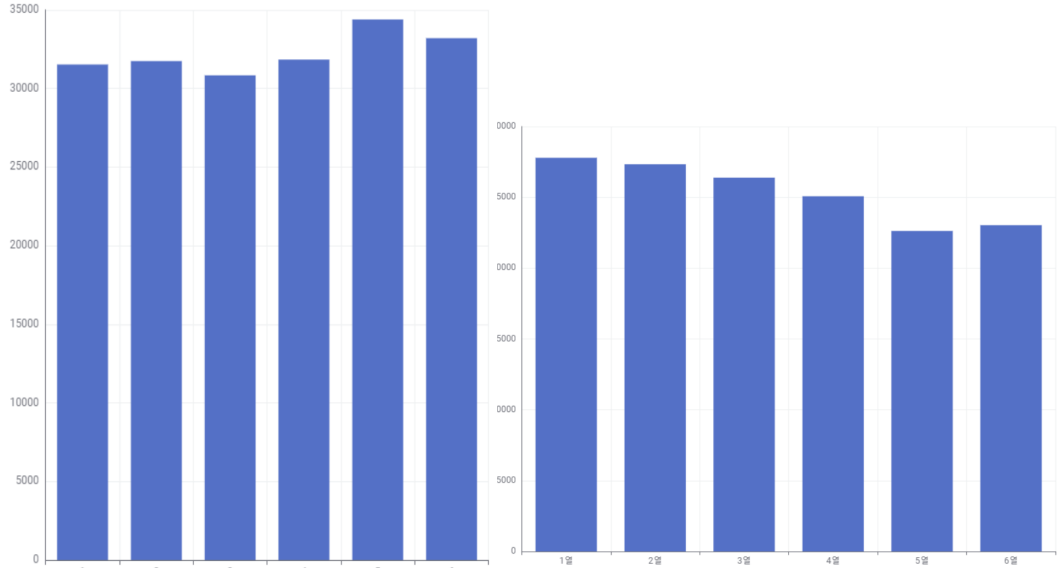


열별 가격비교

그래프 윗줄 : 1층 a,c블록

그래프 아랫줄 : 1층 b블록, 2층 a,b블록

→ 앞쪽 열일수록 가격이 높고 뒤쪽 열일수록 가격이 낮음 1층 b블록 같은 경우 동일한 규칙을 가지지만 가운데열은 가격이 높은 경향이 있음.

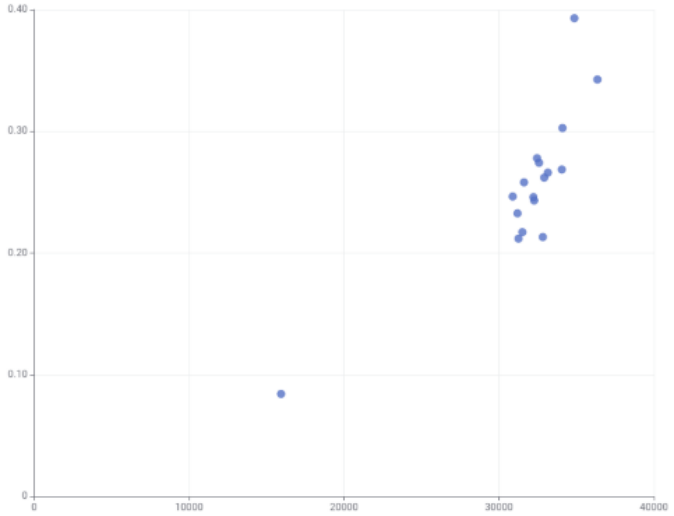


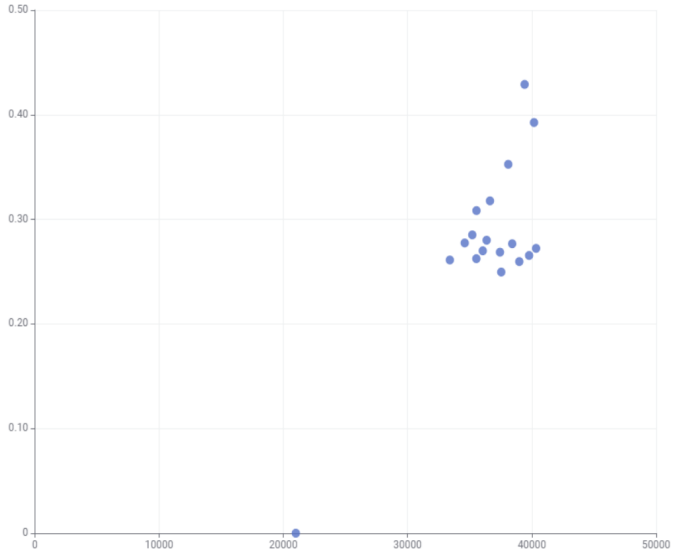
좌석번호별 가격비교

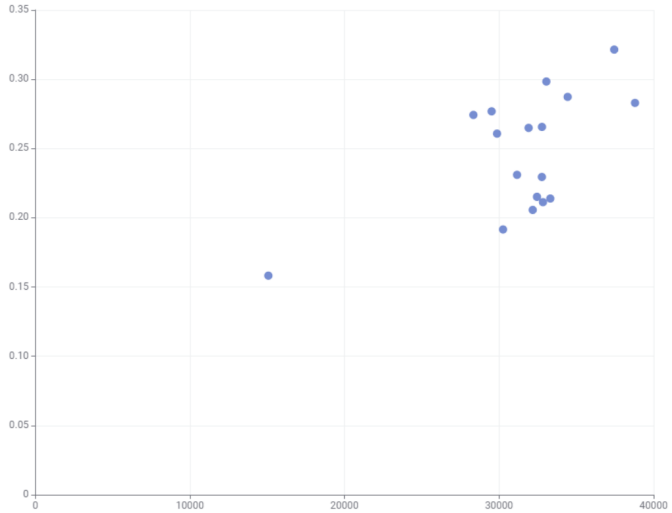
순서대로 1층 a,c블록

→ 중앙 쪽에 위치한 좌석번호일수록 가격이 높게 나옴

장소의 좌석과 목표변수 Y1, Y2와의 관계 -IBK 챔버홀







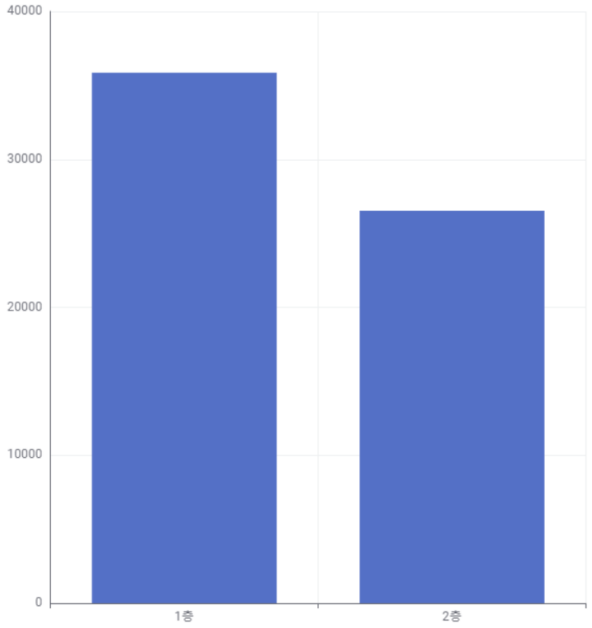
좌석-가격을 바탕으로 한 티켓취소비율의 관계

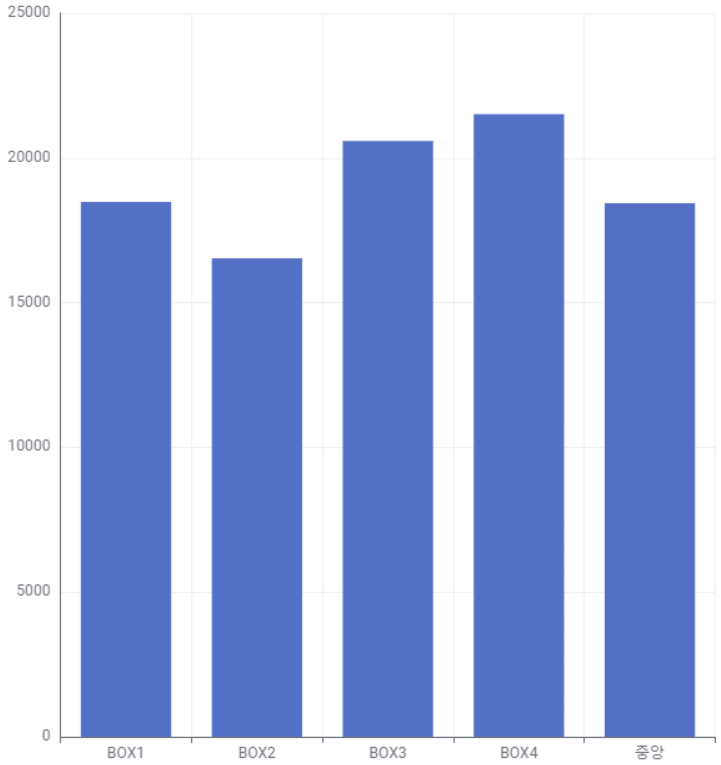
X축 : 가격

y축 : 티켓취소의 비율

→ 산점도와 상관계수를 확인한 결과 1층 A블록 열, 1층 B블록 열, 1층 C블록 열, 2층 A블록 열들은 가격이 높을수록 티켓취소 비율도 높게 나옴.

장소의 좌석과 목표변수 Y1, Y2와의 관계 -리사이틀홀





층별 가격비교 , 블록별 가격비교

층 : 2층 〉 1층

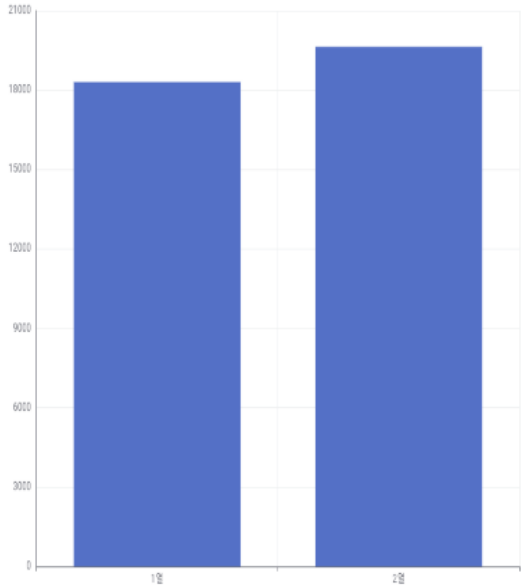
블록 : BOX4 〉 BOX3 〉 BOX1 〉 중앙 〉 BOX2

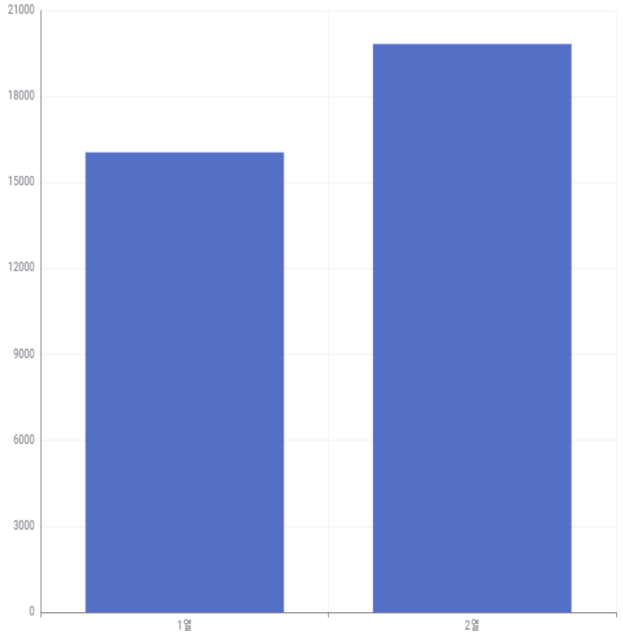
관찰 결과

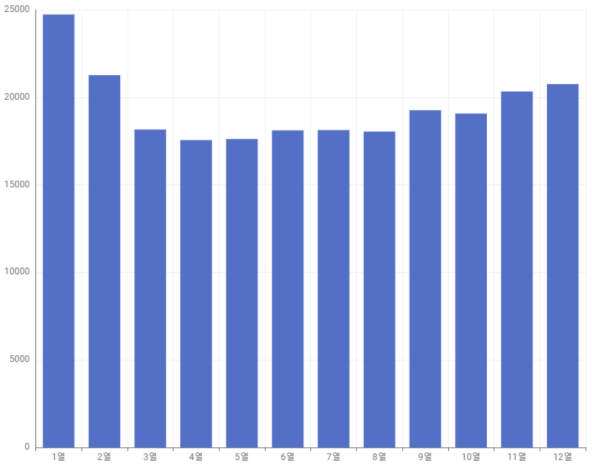
좌석배치도를 참고했을 때, box3과 box4는 위치관계가 같고

평균가격도 비슷해서, 하나로 묶을 수 있음

장소의 좌석과 목표변수 Y1, Y2와의 관계 -리사이틀홀







열별 가격 비교

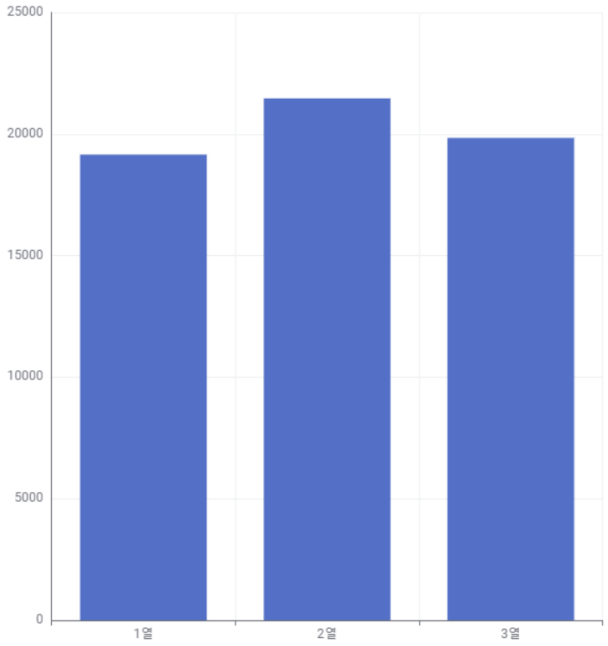
1층 box1 : 2열 〉 1열

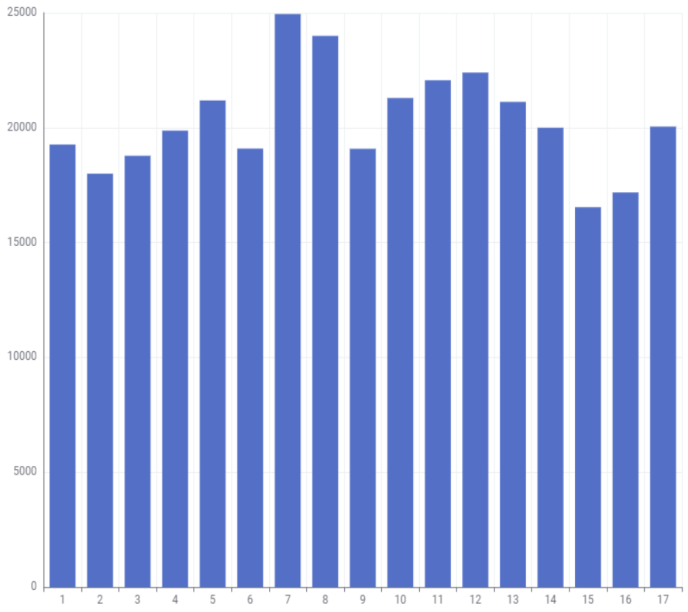
1층 box2 : 2열 〉1열

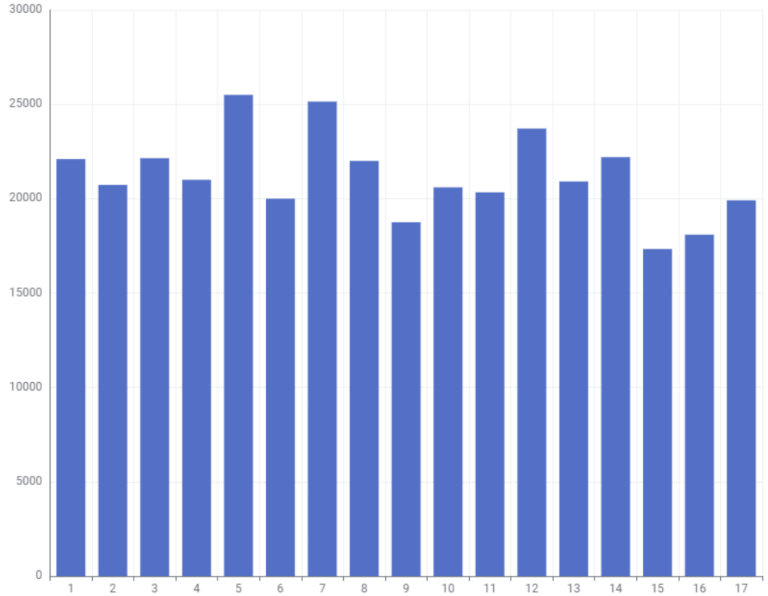
1층 중앙 : 1,2열 〉 11,12열 〉 나머지열

→무대와 가까운 맨 앞 열이거나 가장 먼 맨 뒤 열일 경우에 가격이 높음

장소의 좌석과 목표변수 Y1, Y2와의 관계
-리사이틀홀







열별 가격 비교

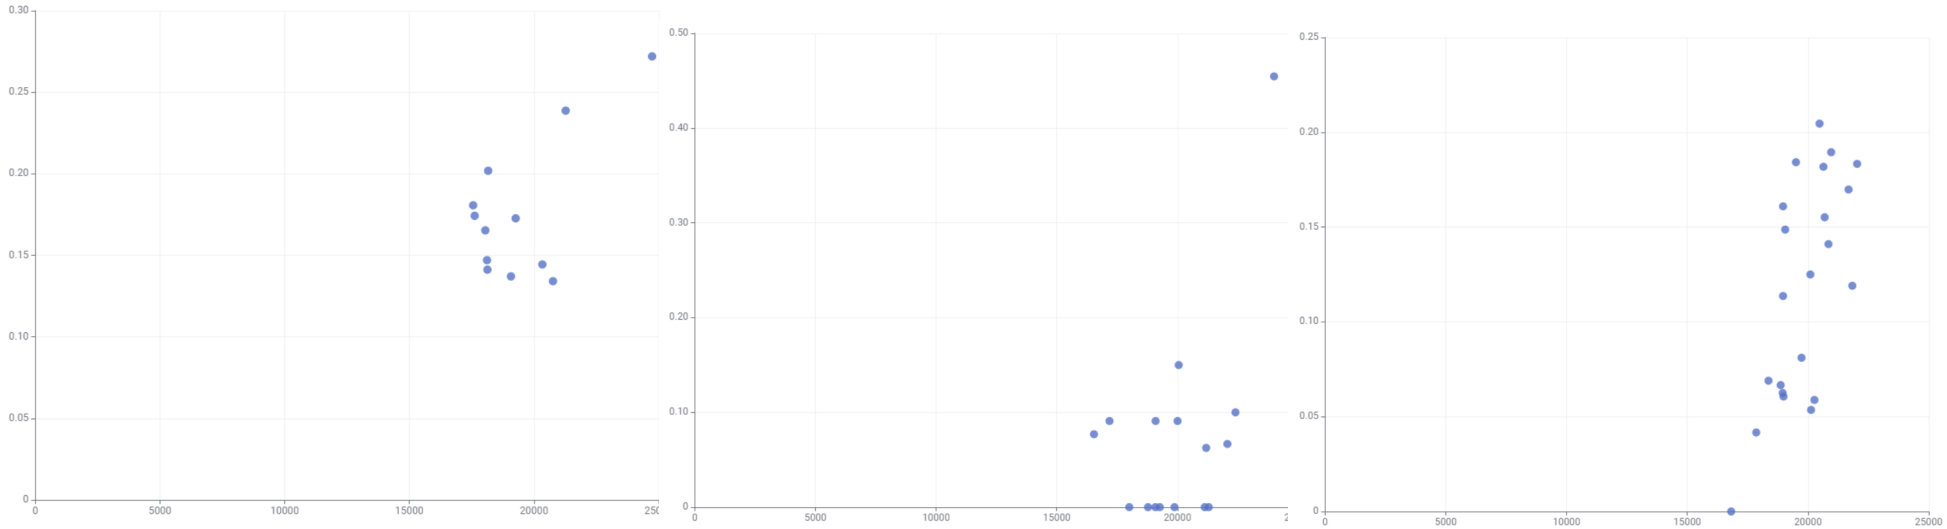
2층 중앙 : 2열〉1,3열

2층 box 1 : 중앙〉가장자리

2층 box 2 : 중앙〉가장자리

→ 2층은 중앙이 가격이 높고 가장자리로 갈수록 가격이 낮아짐

장소의 좌석과 목표변수 Y1, Y2와의 관계 -리사이틀홀

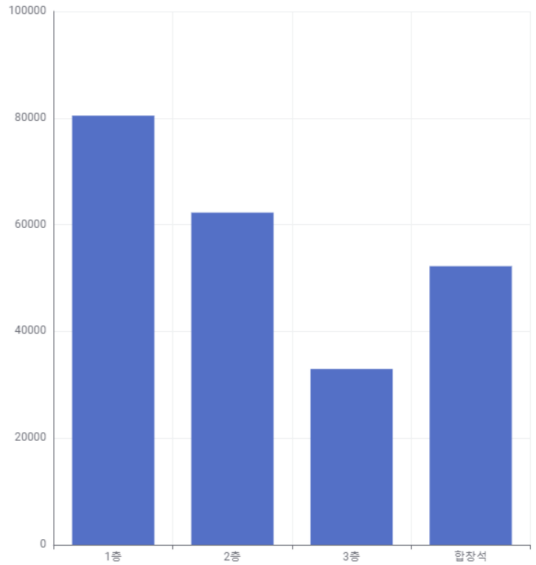


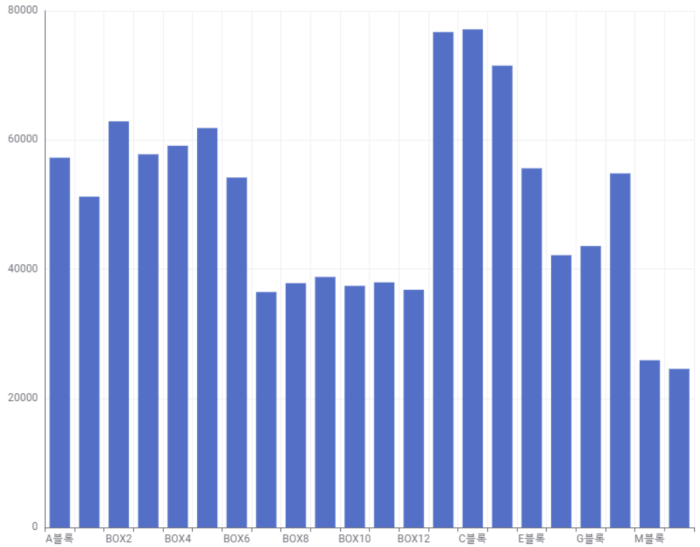
좌석-가격을 바탕으로 한 티켓취소비율의 관계

X축 : 가격, y축 : 티켓취소의 비율

→산점도와 상관계수를 확인한 결과 1층 중앙 열, 2층 box3 좌석, 2층 중앙 좌석은 가격이 높을수록 티켓취소 비율도 높게 나옴

장소의 좌석과 목표변수 Y1, Y2와의 관계 -콘서트홀





층별 가격비교 , 블록별 가격비교

층 : 1층 〉2층 〉합창석 〉3층

블록 : 22개의 블록 중에 가운데 위치한 b,c,d 블록의 가격이 눈에 띄게 높음.

기본사항

- 콘서트홀 같은 경우는 층,블록,열,좌석 모두 매우 많아,

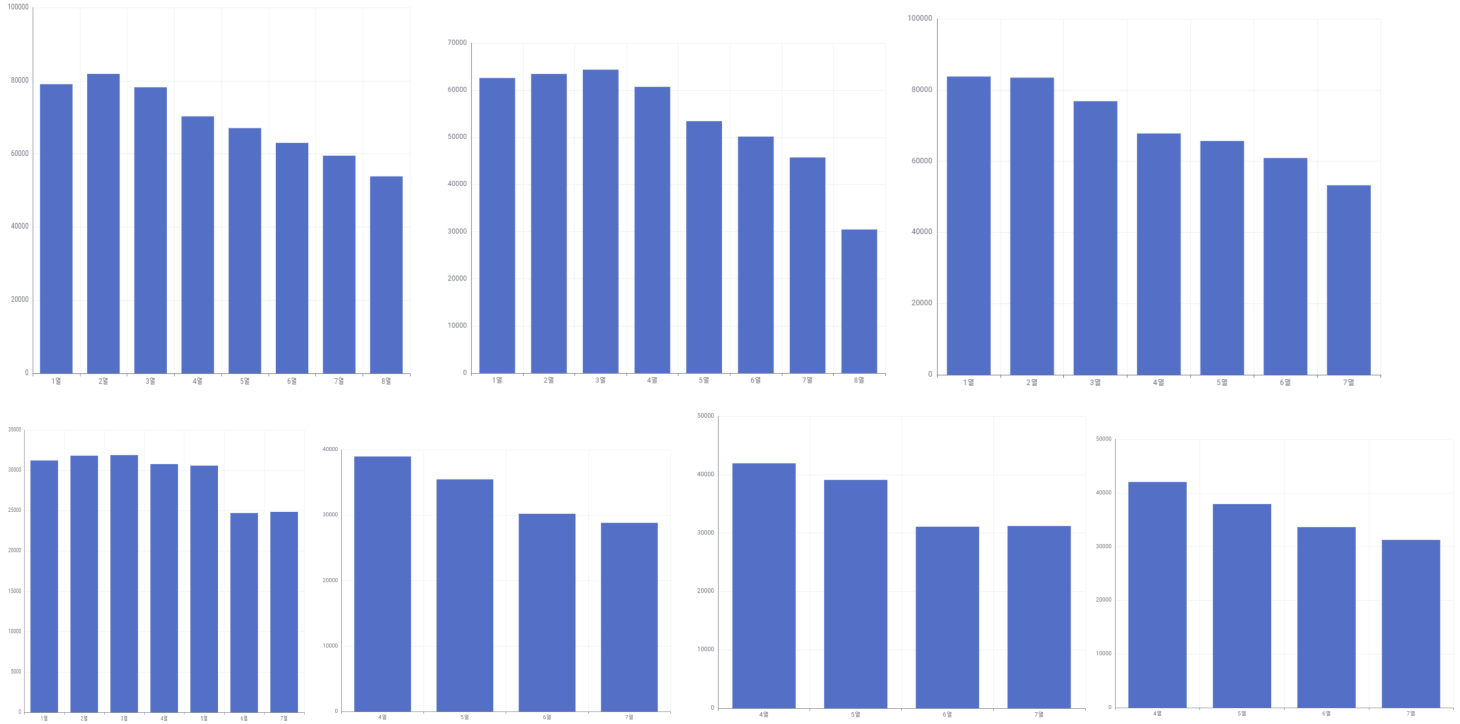
대칭을 기준으로 그룹핑을 우선 진행

→ 1층에서 a와e, b와d 블록을 하나의 그룹으로 그룹핑,

2층에서 b와d a와e, BOX1과6, BOX2와5, BOX3과4를 하나의 그룹으로 그룹핑,

3층에서 a와g, b와f, c와e, m과n, BOX7과12, BOX8과11, BOX9와10을 하나로 그룹핑함.

장소의 좌석과 목표변수 Y1, Y2와의 관계 -콘서트홀

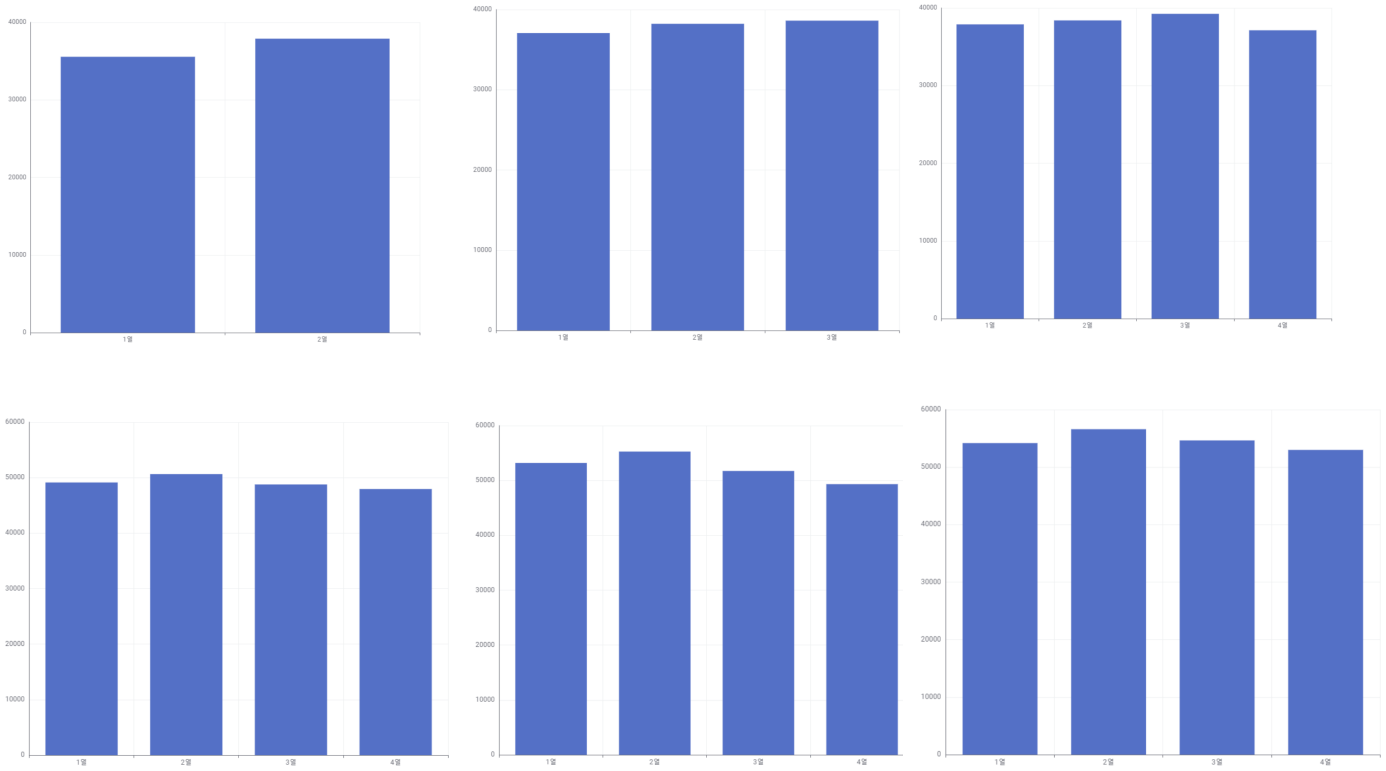


열별 가격 비교

2층의 a~e블록 : 뒤로 갈수록 가격이 하락하는 경향을 보임

3층의 a~g블록 : 뒤로 갈수록 가격이 하락하는 경향을 보임

장소의 좌석과 목표변수 Y1, Y2와의 관계
-콘서트홀



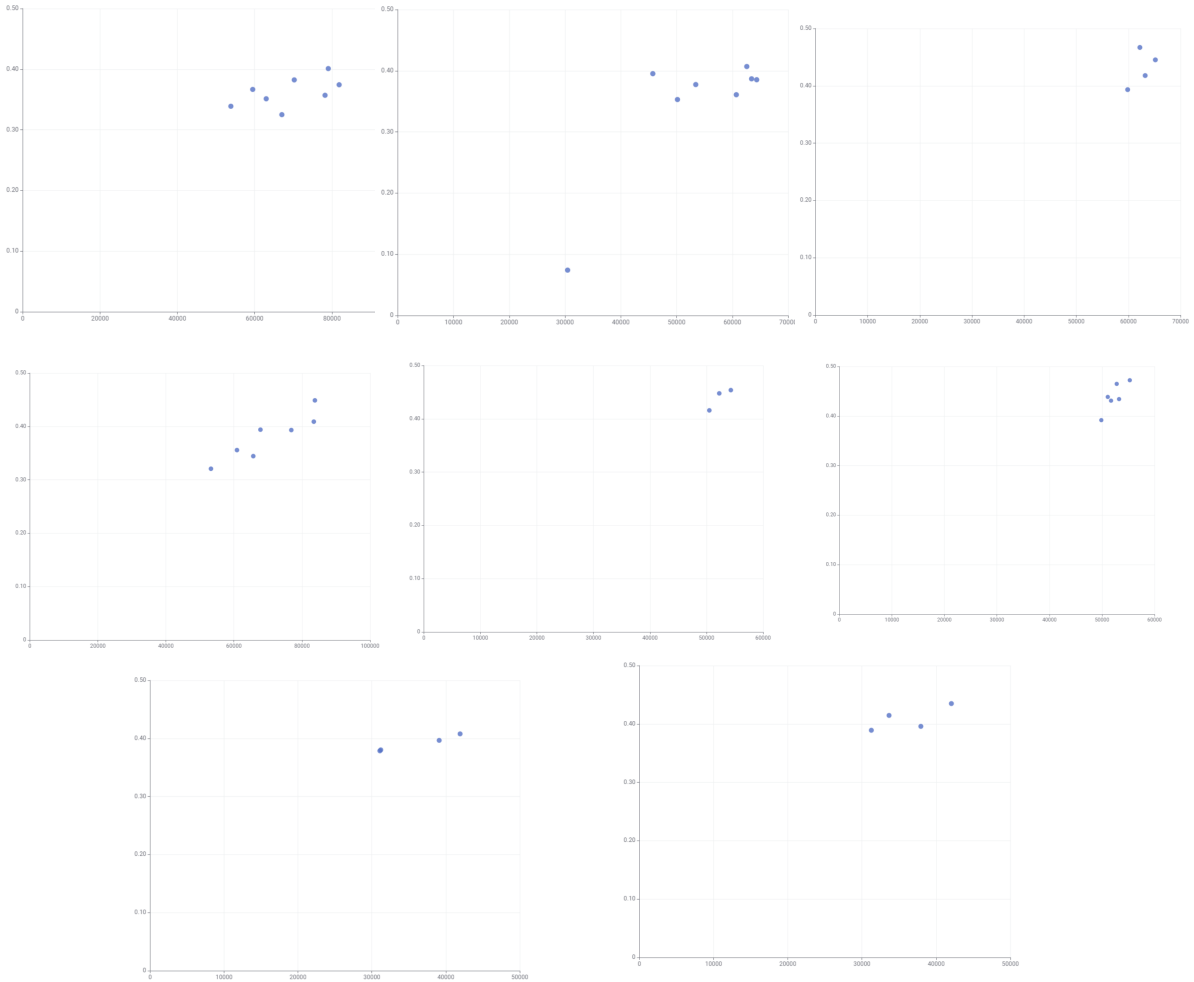
열별 가격 비교

3층 BOX : 뒤로 갈수록 가격이 상승하는 경향을 보임

합창석 f~h : 2열의 가격이 제일 높고 2〉1〉3〉4임.

이 순서가 블록마다 다 동일함

장소의 좌석과 목표변수 Y1, Y2와의 관계 -콘서트홀

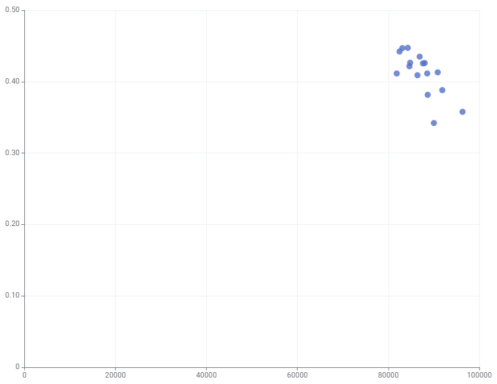


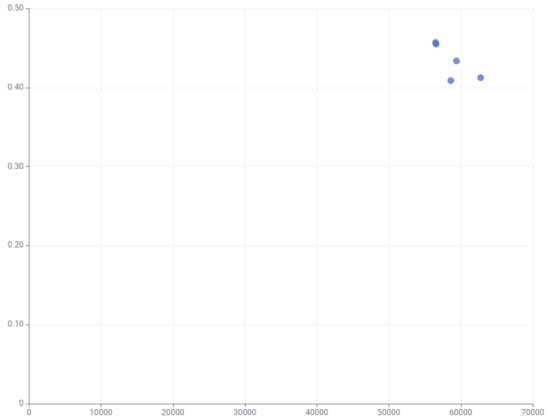
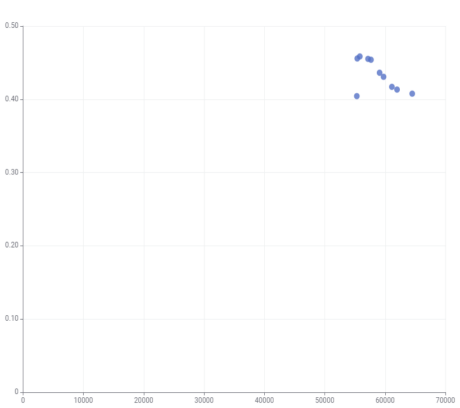
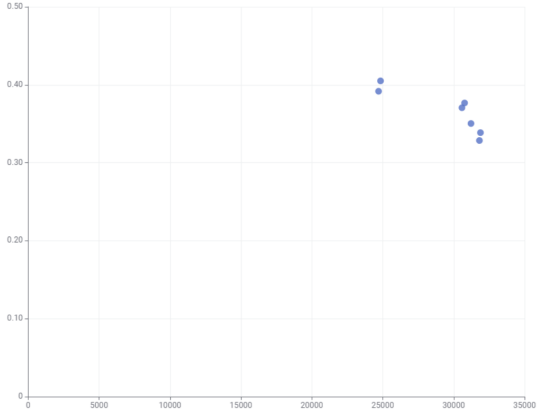
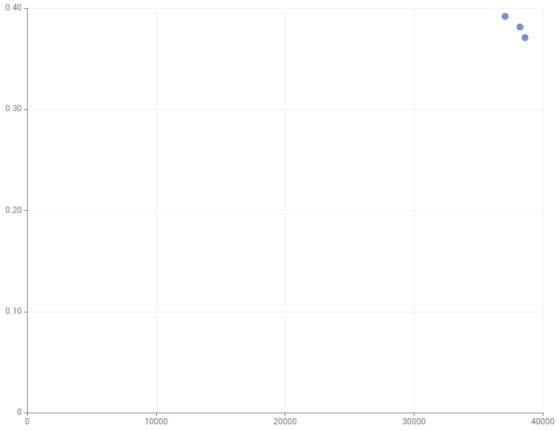
가격을 바탕으로 한 티켓 취소 비율의 관계 : 정비례 관계

2층 b,d블록 열별 2층 a,e블록 열별 2층 box2,5 열별
2층 c블록 열별 2층 box1,6 열별 2층 box1,6 좌석별
2층 box1,6 좌석별 2층 box1,6 좌석별

탐색적 데이터 분석 EDA

장소의 좌석과 목표변수 Y1, Y2와의 관계 -콘서트홀



좌석-가격을 바탕으로 한 티켓취소비율의 관계 : 반비례 관계

1층 c블록 좌석별 1층 b,d블록 좌석별 2층 box3,4 열별

2층 box3,4 좌석별 3층 a,g블록 열별 3층 box8,11 열별

예매데이터 분포 확인

예매 관련 데이터

pre_open_date, open_date칼럼이 예매 관련 데이터이다.

Statistics

Rows: 1 | Columns: 14

Name	Type	# Mi...	# Un...	Mini...	Max...	25%...	50% ...	75% ...	Mean	Mean A... ↓	Standard D...
date_diff	Num...	0	20	-27	366	0	1	1	1.288	1.262	9.645

Statistics

Rows: 1 | Columns: 14

Name	Type	# Mi...	# Unique ...	Mini...	Max...	25% ...	50% Qu...	75% ...	Mean ↓	Mean Ab...	Standard..
date ...	Num...	0	164	1	397	30	41	57	49.622	22.443	35.728

Rows: 20 | Columns: 1

#	RowID	count Number (integer)
1	-27	404
2	-26	330
3	-7	139
4	-6	1409
5	-4	292
6	-1	957
7	0	194013
8	1	272434
9	2	56526
10	3	20179
11	4	8766
12	5	5498
13	6	3342

Rows: 164 | Columns: 1

#	Row...	count Number (integer)
1	1	169
2	2	413
3	4	15761
4	5	1584
5	6	874
6	7	3738
7	8	2630
8	9	2815
9	10	2014
10	11	4364
11	12	4107
12	13	5736
13	14	4592
14	15	5532
15	16	4906
16	17	8951
17	18	7015
18	19	12224
19	20	10618

Pre_open_date 살펴보기

Pre_open_date 와 open_date 차이를 구하고 통계량을 살펴보니 음(-)의 값이 있거나 1년 보다 더 전에 예매를 한 경우가 있음. 이런 값들은 이상치라 생각하고 모델링하기 전에 제거해야함.

Open_date 살펴보기

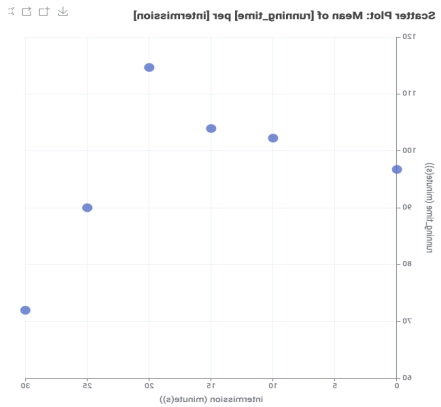
play_date 와open_date 차이를 구하고 통계량을 살펴보니 예매시작일은 공연일보다 모두 적당히 이름. 따라서 open_date에는 오류가 없음.

탐색적 데이터 분석 EDA

공연데이터 분포 확인 및 목표변수 Y1, Y2와의 관계

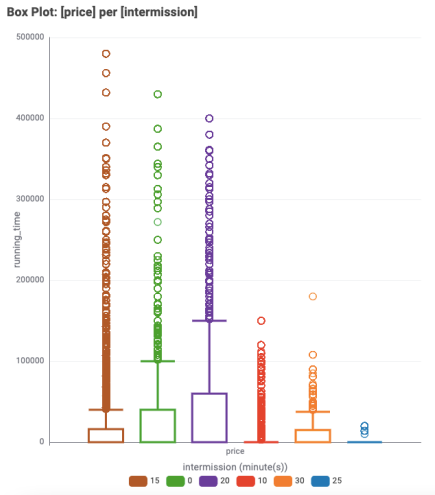
공연 관련 데이터

play_date, play_st_time, intermission, running time 칼럼이 공연 관련 데이터이다.



인터미션과 러닝타임의 관계

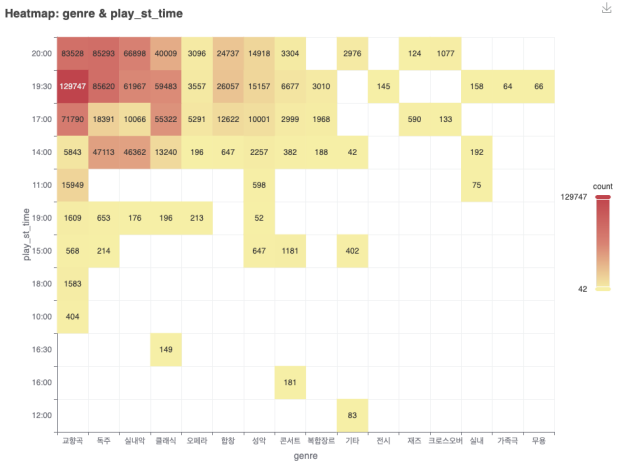
산점도를 살펴본 결과, 인터미션과 러닝타임은 정비례 관계임.



인터미션,러닝타임과 가격과의 관계

Linear correlation 확인 결과, correlation value가 매우 낮아 거의 무관하다고 볼 수 있음.

Box Plot으로 인터미션과 가격의 관계를 살펴보니, 인터미션이 길수록 가격대가 높음을 알 수 있음.



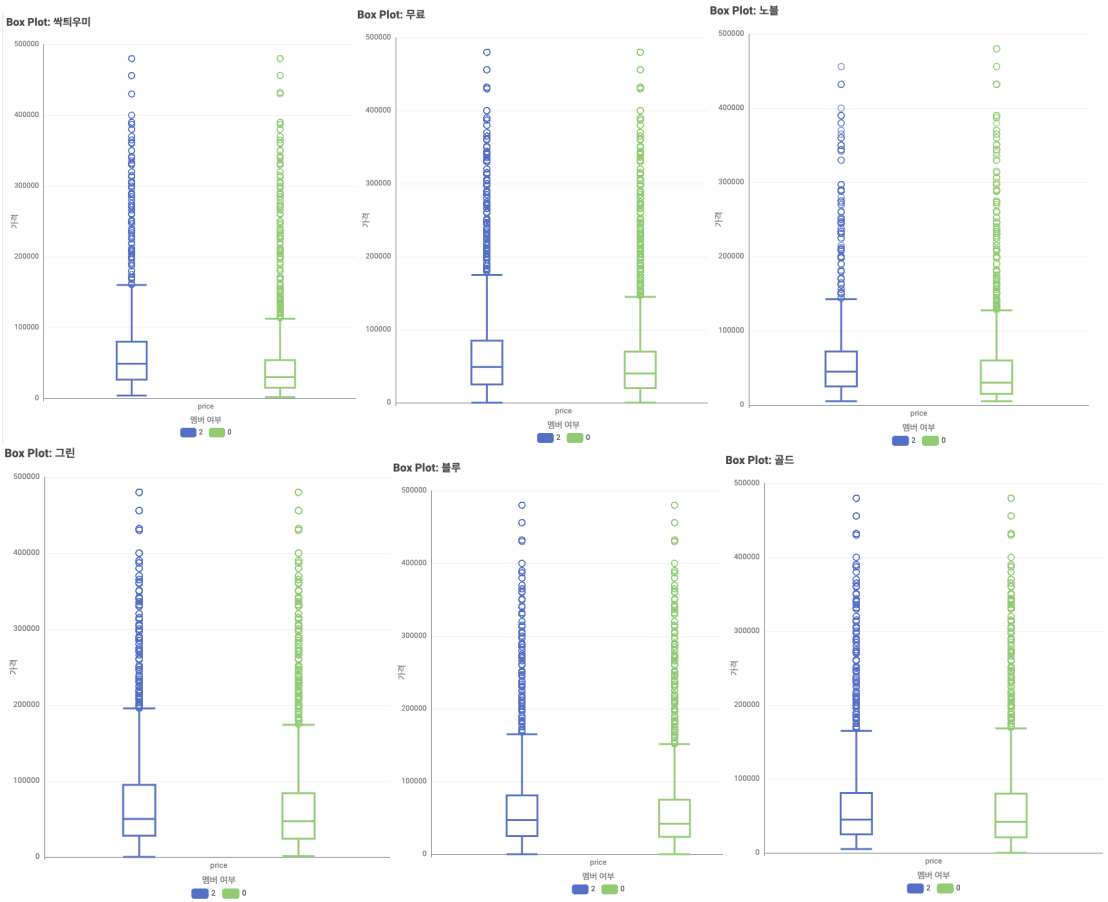
Play_st_time의 분포 확인

play_st_time가 어디에 몰려있는지 알아보기 위해 heatmap 그렸음.

이 결과 주로 많은 공연이 저녁시간대에 시작한다는 것을 알 수 있었음

멤버십과 목표변수 Y1, Y2와의 관계

멤버십별 취소한 티켓과 취소하지 않은 티켓의 가격대 비교



Box Plot 그리기

각 멤버십의 회원인 행들을 추출하고 box plot을 이용해 취소한 티켓과 취소하지 않은 티켓의 가격 box plot을 그림.

Ex) 싹트우미 멤버십을 보유한 사람의 취소한 티켓과 취소하지않은 티켓의 가격대 비교

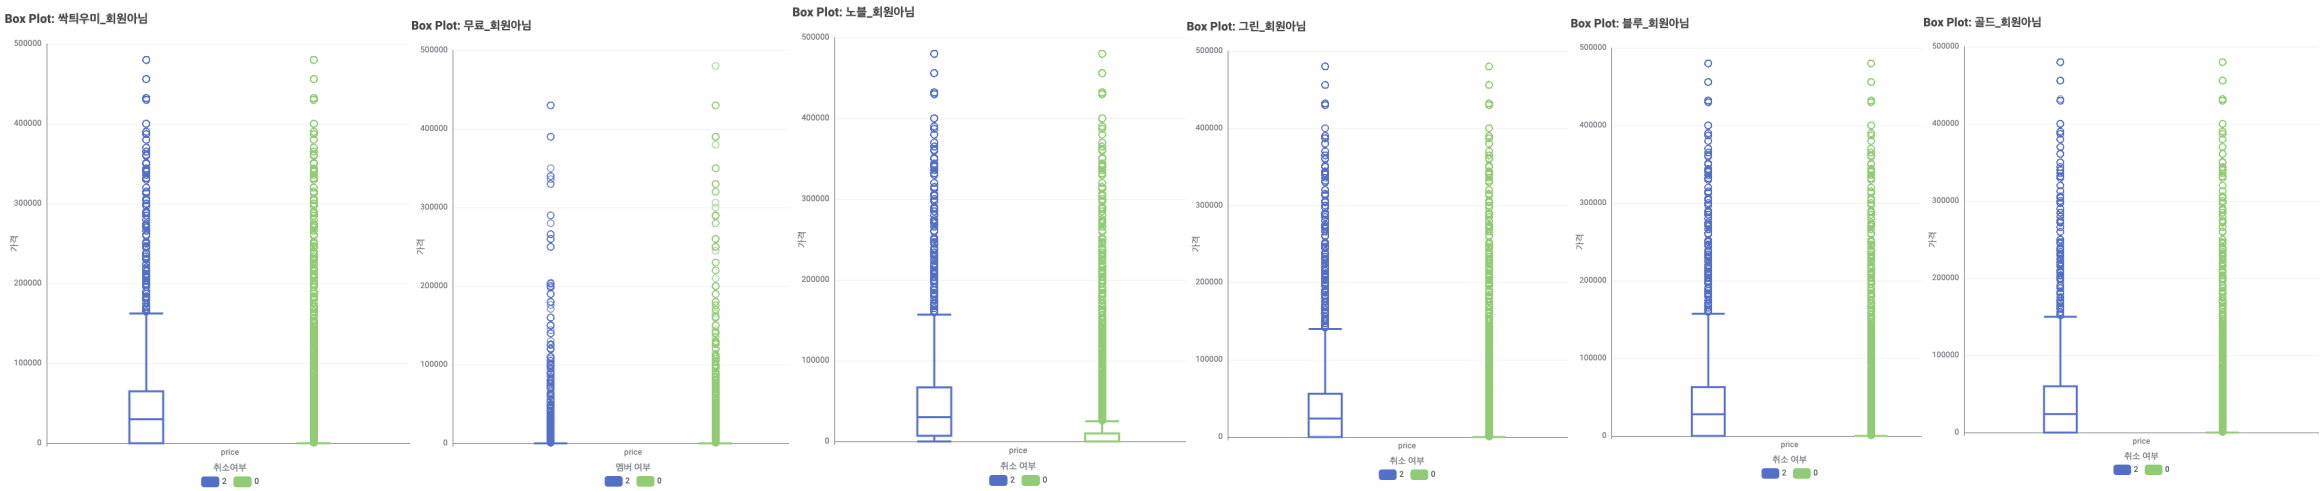
분석결과

“취소한 티켓의 가격대 〉 취소하지 않은 티켓의 가격대” 이 모든 멤버십에 적용됨

탐색적 데이터 분석 EDA

멤버십과 목표변수 Y1, Y2와의 관계

해당 멤버십을 보유하고 있지 않을 경우에 취소한 티켓과 취소하지 않은 티켓의 가격대 비교



Box Plot 그리기

각 멤버십의 회원이 아닌 행들을 추출하고 취소한 티켓과 취소하지않은티켓의 가격 box plot을 그림

Ex) 싹틔우미 회원이 아닌 사람들이 취소한 티켓과 취소하지 않은 티켓의 가격대 비교

분석 결과

"취소한 티켓의 가격대 〉 취소하지 않은 티켓의 가격대"이 특정 멤버십을 보유하지 않는 경우에 모두 적용됨

더해서 앞 슬라이드와 비교했을 때, 특정 멤버십이 아닐 경우에 취소티켓과 취소하지않은 티켓의 가격대가 더 눈에 띄게 차이남. 이는 멤버십이 적용될 경우에 티켓을 취소할 확률이 낮아진다고 해석할 수 있음.

콘서트홀 공연별 가격 예측 모델

1) 1차 모델링

목적: 콘서트홀의 예매 데이터에 대한 최종 예매 가격을 예측하는 모델 설계

분석 대상: 공연 장소 (place) 가 '콘서트홀' 이면서 최종 예매 가격이 "0" 이 아닌 데이터 (총 282,815개의 행)

독립 변수 (X) : 전처리 데이터 중 price 를 제외한 나머지 모든 칼럼

성별, 나이, 싹틔우미, 무료, 노블, 그린, 블루, 골드, 거래날짜, 거래시간, 공연날짜, 공연시작 시간, (좌석의) 층, 블록, 열, 좌석번호, 예매 취소 여부, 할인내역, 공연명코드, 선예매시작일, 예매시작일, 장르, 공연장소, 러닝타임, 휴게시간, 회원여부

종속 변수 (Y) : 최종 예매 가격 (price) (연속형)

머신 러닝 기법 : 선형 회귀 분석, 회귀결정나무, 랜덤회귀결정나무, Gradient Boosting Machine (회귀),
Extreme Gradient Boosting (트리 기반 회귀 XGBoost)

1) 1차 모델링

모델링 결과

파라미터 조정 및 투입되는 독립변수를 조정하고, 여러 성능 평가 방식을 사용하였음에도 모든 머신러닝 기법에 대해서 조정된 R 스퀘어 값이 0.6 보다 작게 나왔고, 오류에 대한 평가 지표들의 값도 크게 나왔음

성능 부족 원인 분석

최종 예매 가격이 할인이라는 요소에 매우 크게 영향을 받고 있음. 같은 공연의 거의 동일한 위치의 좌석이라도
할인율이 다르면 최종 예매 가격이 달라짐

콘서트홀 공연별 가격 예측 모델

1) 1차 모델링

성능 부족 원인 분석 _ 근거 (EDA)

공연명코드, 좌석의 "층", 좌석의 "블록"
조합을 기준으로 데이터들을 그룹화하고
각 그룹에 소속된 데이터의 가격의 유일값을
집합에 저장하였음

그룹 별 가격 집합 내에 최대 11개의 가격 유일값이 존재하기도 하였음

예술의 전당에서는 가격을 만원 단위로 나누는데, 예매 가격의 유일값간의 차이는 천원 단위로 나타남

S 층	S 블록	I perfor...	[...] Set*(price)	S Mode(genre)
1층	A블록	1	[42000,60000]	클래식
1층	A블록	3	[45000,90000,72000,...]	클래식
1층	A블록	23	[45000,50000,32000,...]	교향곡
1층	A블록	38	[50000,76000]	클래식
1층	A블록	39	[95000,100000,47000,...]	실내악
1층	A블록	42	[140000,133000,171000,...]	클래식
1층	A블록	43	[72000,42000,50000,...]	합창
1층	A블록	44	[289000,306000,170000,...]	교향곡
1층	A블록	54	[16000,48000,20000,...]	클래식
1층	A블록	64	[90000,81000,85000,...]	클래식
1층	A블록	68	[120000,84000,63000,...]	교향곡
1층	A블록	71	[84000,120000,96000]	교향곡
1층	A블록	76	[36000]	클래식
1층	A블록	77	[40000,32000]	클래식
1층	A블록	78	[18000,15000,30000,...]	교향곡
1층	A블록	79	[40000,10000,30000,...]	교향곡
1층	A블록	80	[24000,30000,16000,...]	교향곡
1층	A블록	81	[16000,40000,24000,...]	교향곡
1층	A블록	95	[14000,30000,12000,...]	합창
1층	A블록	96	[24000,18000,30000,...]	합창
1층	A블록	98	[10000,16000,20000,...]	합창
1층	A블록	104	[25000,35000,37000,...]	교향곡
1층	A블록	105	[351000,390000,370000]	교향곡
1층	A블록	108	[90000,54000,60000,...]	교향곡
1층	A블록	119	[27000,18000,50000,...]	교향곡

할인내역 (discount_type) 칼럼 (ex.블루회원 할인 15%) 을 통해서 설명 가능
정가에 할인율이 적용되면서 최종예매가격이 변화하고, 천원 단위의 가격 구간이 생성됨

2) 특성 공학 - 1

목적: 정가 (undiscounted_price) 컬럼 생성

※ 예술의 전당에서 책정한, 할인되기 전의 티켓의 가격

데이터 조작 방법

1. 할인내역 (discount_type) 에서 N% 로 표현된 할인율을 숫자로 추출
   (이때, “일반 " 데이터는 할인율 =0)
2. 추출된 값을 할인율 컬럼에 저장
3. { 최종예매가격 * 100 / (100-할인율) } 이라는 수식을 적용하고 그 값을 만의 자리까지 올림하여, “정가” (undiscounted_price) 칼럼을 생성

   ※ 최종예매가격(price)은 1000의 자리 이하의 값은 버림한 값이기 때문에, 수식을 적용하였을 때에 정가가 소수점으로 나오는 행들에 대해 올림 처리

undiscounted_price
30000
90000
40000
100000
120000
90000
30000
40000
120000
30000
50000
120000
10000
90000
90000
60000
50000
20000
70000
180000
90000
180000

콘서트홀 공연별 가격 예측 모델

2) 특성 공학 – 2

공연명코드, 좌석의 "층", 좌석의 "블록"
조합을 기준으로 데이터들을 그룹화하고
각 그룹에 소속된 데이터의 가격의 유일값을
집합에 저장하였음

층, 블록, 장르가 같아도, 공연명 코드에 따라서 가격 차이가 극명하게 나타남

ex) 공연 코드명 105, 44 : 다른 교향곡의 5배~ 10배 이상

이러한 극적인 차이는, 공연 시간, 공연 길이, 쉬는 시간 등의
요소보다는 공연의 인기도에 의해서 나타난다고 보는 것이
합리적

S 층	S 블록	I perfor...	[...] Set*(price)	S Mode(genre)
1층	A블록	1	[42000,60000]	클래식
1층	A블록	3	[45000,90000,72000,...]	클래식
1층	A블록	23	[45000,50000,32000,...]	교향곡
1층	A블록	38	[50000,76000]	클래식
1층	A블록	39	[95000,100000,47000,...]	실내악
1층	A블록	42	[140000,133000,171000,...]	클래식
1층	A블록	43	[72000,42000,50000,...]	합창
1층	A블록	44	[289000,306000,170000,...]	교향곡
1층	A블록	54	[16000,48000,20000,...]	클래식
1층	A블록	64	[90000,81000,85000,...]	클래식
1층	A블록	68	[120000,84000,63000,...]	교향곡
1층	A블록	71	[84000,120000,96000]	교향곡
1층	A블록	76	[36000]	클래식
1층	A블록	77	[40000,32000]	클래식
1층	A블록	78	[18000,15000,30000,...]	교향곡
1층	A블록	79	[40000,10000,30000,...]	교향곡
1층	A블록	80	[24000,30000,16000,...]	교향곡
1층	A블록	81	[16000,40000,24000,...]	교향곡
1층	A블록	95	[14000,30000,12000,...]	합창
1층	A블록	96	[24000,18000,30000,...]	합창
1층	A블록	98	[10000,16000,20000,...]	합창
1층	A블록	104	[25000,35000,37000,...]	교향곡
1층	A블록	105	[351000,390000,370000]	교향곡
1층	A블록	108	[90000,54000,60000,...]	교향곡
1층	A블록	119	[27000,18000,50000,...]	교향곡

공연의 인기도가 가격에 영향을 주고 있는 것으로 예측됨
공연이 얼마나 많은 관심을 받고 있는지를 대표할 특성이 필요함

2) 특성 공학 - 2

- 목적: 시작일예매비율 (open_date_transaction_ratio) 컬럼 생성하기

  ※ 시작일예매비율이란?

  어떠한 공연에 대해 이뤄진 모든 예매 중에서, 선예매시작일 혹은

  예매 시작일에 거래된 예매의 비중

- 논리: 인기가 많고 주목을 많이 받는 공연과 자리일수록, 선예매나 예매 시작일에 티켓팅이 몰릴 것이다.

데이터 조작 방법

1. 각 공연명코드 별로, 선예매시작일 혹은 예매시작일에 거래가 이루어진 예매 내역의 총 개수를 구한다. { 거래일자와 (선)예매시작일을 비교, count 활용}

   Ex) 공연명코드가 330인 행 중에, 15개가 선예매시작일에 거래됨 -> 15

2. 위에서 구한 값을 각 공연명코드 에 대응되는 모든 예매 내역의 총 개수로 나눈다.

   Ex) 공연명코드가 330인 행은 총 100개 있음 -> 100

3. 위에서 구한 값을 공연명코드에 1:1 대응하여 각 데이터의 시작일예매비율에 저장한다.

   Ex) 공연명코드가 330인 행의 시작일예매비율은 15 / 100= 0.15

D open_date_transaction_ratio
0.385
0.193
0.203
0.114
0.018
0.047
0.156
0.303
0.134
0.229
0.164
0.126
0.033
0.213
0.247
0
0.28
0.111
0.061
0.074
0.081
0.023
0.026

3) 2차 모델링

- 목적: 콘서트홀의 공연정보, 예매정보에 대한 정가 (undiscounted_price)를 예측하는 모델 설계
- 분석 대상: 공연 장소 (place) 가 '콘서트홀' 이면서 최종 예매 가격이 "0" 이 아니면서

  할인율을 바탕으로 정가를 추정할 수 있는 데이터 (총 273716개의 행)

독립 변수 (X) : 예매 정보 컬럼 + 공연 정보 컬럼 (특성공학으로 만들어진 컬럼 포함)

예매 거래일자, 예매 거래시간 공연날짜, 공연시작시간, 층, 블록, 열, 좌석번호, 예매취소여부, 공연명코드, 선예매시작일,
예매시작일, 장르, 공연장소, 러닝타임, 휴게시간, 시작일예매비율

※ 1차 모델링에서 예매자와 관련된 특성은 제외되고, 시작일예매비율이 추가됨

종속 변수 (Y) : 정가 (undiscounted_price) (연속형)

머신 러닝 기법 : 선형 회귀 분석, 회귀결정나무, 랜덤회귀결정나무, Gradient Boosting Machine (회귀),
Extreme Gradient Boosting (트리 기반 회귀 XGBoost)

3) 2차 모델링

모델링 결과

머신러닝 기법 중 **단순 회귀결정나무 (Regression Decision Tree)** 가 가장 높은 성능을 보여줌.

성과 지표 (.K-fold 교차 검증 (k=10) 기준)

R 스퀘어 : 0.995

평균 절대 오차 (Mean Absolute Error) : 654.933

평균 제곱 오차 (Mean Squared Error) : 21679.84

평균 제곱근 오차 (Root Mean Squared Error) : 4656.16

평균 부호화된 차이 (Mean Signed Difference) : 91.62

평균 절대 백분율 오차 (Mean Absolute Percentage Error) : 0.014

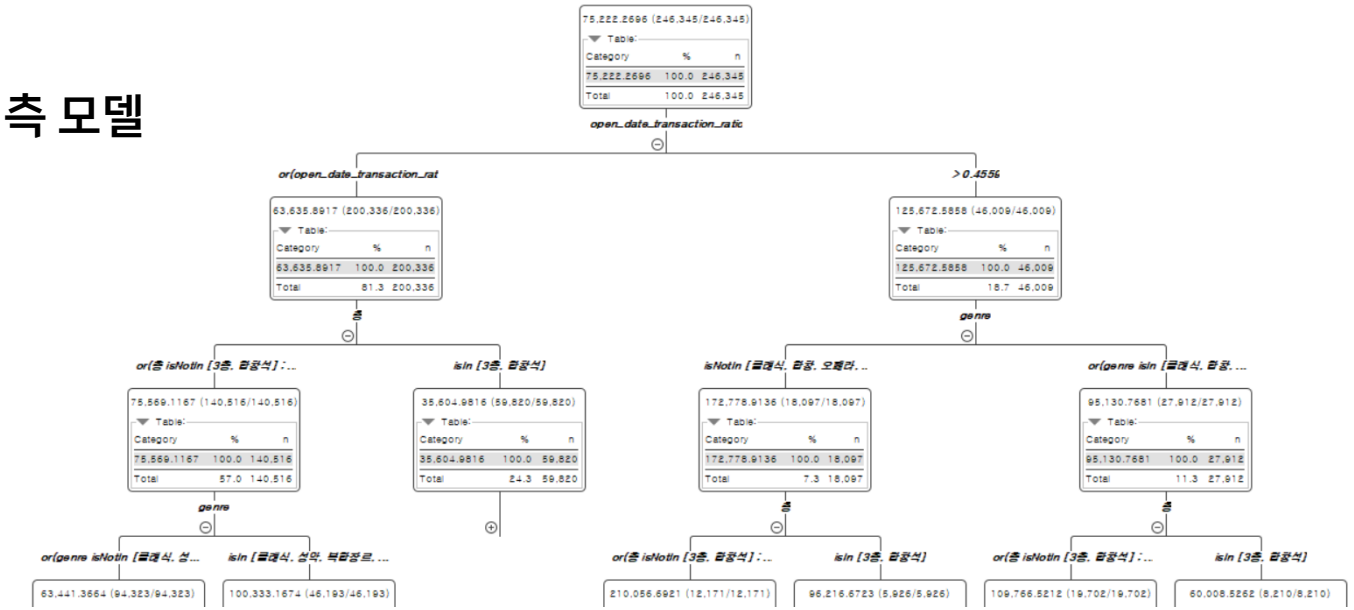
결정계수 (조정된 R 스퀘어) : 0.995

예측모델임에도 불구하고 273,716 개의 데이터 중 265,883 개 (97.13%) 의 데이터에 대한 정가를 완전히 정확하게 예측함.

결과 활용 및 시사점

1) 분석결과 활용

a. 콘서트홀 공연 가격 예측 모델



1) 설명력이 매우 높은 모델 (수정된 R 제곱값 0.995) 이 설계되었고, 만들어진 모델이 결과 해석이 가능한 〈회귀결정나무〉 이기 때문에, 그림에 나타난 것과 같은 회귀나무에 대한 탐구를 통해 예술의 전당 가격 책정 경향성을 파악할 수 있음.

2) 모델에서 실제보다 가격을 높거나 낮게 예측한 7,833 개의 데이터에 대해서, 가격 인상/ 인하를 검토해볼 수 있음.

→ 이 과정에서 시작일예매비율 (open_date_transaction_ratio) 도 확인하면, 가격 조정에 합리성 부여 가능.

3) 선예매 당시의 예매 경쟁률을 바탕으로, 본 예매의 적정가격을 재책정할 수 있다.

-어떤 예매의 선예매에 대한 시작일예매비율을 본 회귀결정나무에 대입, 적정 가격을 예측

1) 시사점

a. 콘서트홀 공연 가격 예측 모델

1) 공연의 시작일 예매비율(인기도 측정 지표)은 공연의 좌석별 정가에 매우 큰 영향을 미치고 있다.
정가 예측 모델에 시작일예매비율 (open_date_transaction_ratio) 을 포함시키는지 여부에 따라서, R스퀘어 값이 0.7(0.9 - 0.2) 이상 차이가 났다.

2) 더 정교한, 공연의 인기도 추정 칼럼들을 생성할 수 있다.
본 분석에서는 거래 날짜와 예매시작일자만 비교하였지만, 보다 세부적으로 거래시간과 예매시작시간까지 비교할 수 있다면 각 공연의 인기도를 더 정교하게 측정할 수 있다.

3) 신규 공연에 대해서 가격을 예측 (책정) 할 수 있는 방법이 필요하다.
- 본 모델의 가장 큰 약점은 최초 공개작에 대해서는 가격을 예측할 수 없다는 점.
- 1) 에서 제시된 바와 같이, 가격 예측 모델에서 시작일예매비율이 수행하는 역할이 너무 크기 때문임.
- 출연 배우, 공연 시간, 공연 디렉터 등 예매가 시작되기 전에도 파악할 수 있는 특성을 독립변수 (X) 로 하고, 공연의 시작일예매비율 혹은 인기도를 대변하는 다른 변수를 종속변수 (Y) 로 설정하는 다른 모델을 설계하여 이러한 한계 극복 가능

콘서트홀 취소표 예측 모델

- 부수적 모델 -

콘서트홀 취소표 예측 모델



I. 취소표 모델 1~4

모델 별 특징 및 해설

II. 취소표 모델링 결과 활용

모델링을 통해 발견한 인사이트 및
도출 가능한 마케팅 플랜

III. 취소표 모델링 시사점

모델링을 통한 기대효과

목표: 예술의전당 콘서트홀 티켓 취소 여부를 예측하는 모델 제작

목표변수 = 취소여부*

*칼럼명 'ticket_cancel'

독립변수 = 목표변수 외 모든 변수들 + 가격 모델링에서 새로 만든 변수 3개*

*칼럼명 '할인율', 'undiscounted_price', 'open_date_transaction_ratio'

모델 1. 할인 미적용 가격을 이용한 모델링

"할인율 OR 멤버십, 둘 중 택 1"

- 예매자가 보유한 멤버십에 따라 할인율이 결정
- 멤버십과 가격 변수를 중복으로 독립변수로 이용할 필요 X

- 따라서, 아래 가격 관련 변수들을 모델링에서 제외:
- 가격, 할인율, undiscounted_price, open_date_transaction_ratio

- 대신, 멤버십 변수는 보존

모델 2. 데이터 균형화 후 검증 데이터셋으로 feature selection 직접 진행해 모델링

"티켓취소 여/부 데이터 균형화"

- 목표변수인 티켓취소여부(ticket_cancel)의 분포: 여/부 데이터 개수의 비대칭 존재
- 따라서, 모델의 성능을 높이고자 데이터 균형화 작업을 사전 진행 후 모델링 실시

- 이후 검증 데이터셋의 예측 결과에서 잘못 예측된 행들과 올바로 예측된 행들을 분리
- ['실제2, 예측0' 데이터셋 vs. '실제2, 예측2' 데이터셋] 칼럼별 분포 비교

→ 각 비교에서, 서로 다른 분포를 보이는 칼럼은 ticket_cancel 값이 동일한 '실제2' 값이지만, 잘못된 예측을 하는 데 영향을 준 칼럼이라고 판단하여 제외하고 모델링

- ['실제0, 예측2' 데이터셋 vs. '실제0, 예측0' 데이터셋] 칼럼별 분포 또한 마찬가지 방법으로 활용

모델 3. 취소여부 특이점을 보이는 멤버십을 기준으로 데이터셋을 분할해 모델링

"티켓취소여부 특이점이 보이는 멤버십 추출"

- 앞서 EDA를 진행하면서 **가격과 티켓취소여부 간 상관관계**가 꽤 큰 편임(correlation value 〉 0.6)을 확인
- 이때 눈에 띈 특이점(칼럼) : **노블회원**

→ **노블회원이면(If 노블=1),** 취소비율이 다른 회원일 경우의 취소비율보다 압도적으로 낮음

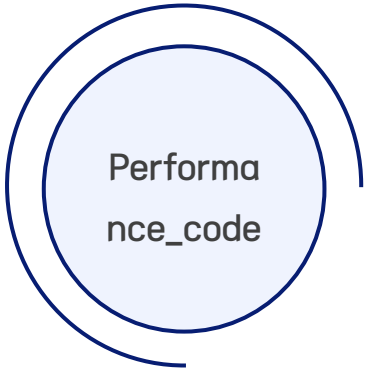
→ **노블회원이 아니면(If 노블=0),** 가격과 취소비율이 정비례 관계, 즉 취소표의 가격대가 취소하지 않은 표의 가격대보다 월등히 높음

- 따라서, **노블회원인 경우와 아닌 경우로 분리하여** 모델을 만들어야 성능이 좋아질 것으로 판단

→ 노블회원이 다른 멤버십 회원들에 비해 특이점을 보이고 있으므로, 따로 떼어 모델링

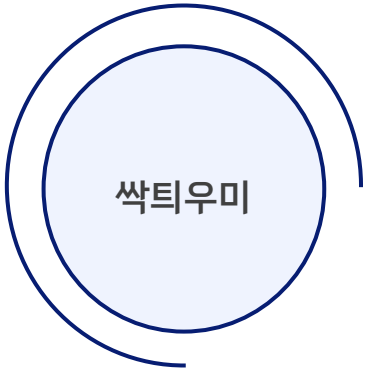
모델 3. 취소여부 특이점을 보이는 멤버십을 기준으로 데이터셋을 분할해 모델링

이 모델에서 제외한 칼럼들:



멤버십에 따른 티켓 취소 여부를 보는 것이 핵심

→ 공연별 고유의 코드인 performance_code는 불필요하다고 판단, 제외



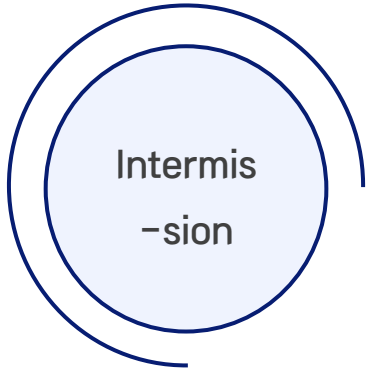
나이 변수와 큰 상관관계
→ 둘 중 나이 변수만 채택

*나이 변수는 다른 멤버십들과도 (낮게라도) 상관관계를 가지므로 함부로 제외하지 않음



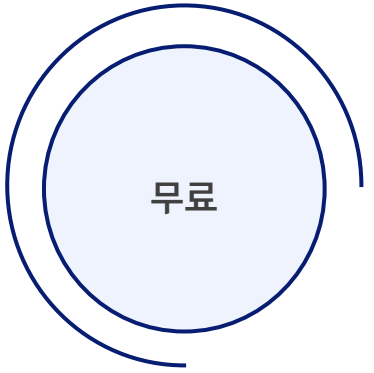
머신러닝 기법은 local date/time 변수를 인식 X

→ 날짜 및 시간 관련 변수들 대신 가격 모델 생성 시 만들었던 open_date_transaction_ratio 활용



인터미션과 러닝타임은 전체 데이터 수 대비 상대적으로 소수인 데이터만 제외하면 정비례 관계

→ 둘 중 조금 더 세분화되어 있는 러닝타임 채택



'무료' = 0 이면, 무조건 다른 모든 멤버십도 0이므로 제외

모델 4. 서로 영향을 주는 변수들을 조작하여 모델링

" 독립변수들 간 관계가 X와 Y의 관계를 흐리지 않도록 칼럼 제외 "

아래 변수들은 다음과 같은 이유로 제외:

price
할인율에 따라 결정됨

member_yn
결국 멤버십 6종류 중 하나라도 보유하고 있느냐 없느냐에 따라 결정됨

undiscounted_price
'할인 적용 전 가격'이므로 가격과 할인율의 영향을 받음

open_date_transaction_ratio
가격과의 correlation value가 큼

II.취소표 모델 결과 활용

1 취소여부와 멤버십

GOLD

- 다른 멤버십 가입여부 무관, 골드회원에 가입한 사람들 중 **티켓취소 비율은 10% 이상**

- 다른 멤버십과 달리 '선물용' 존재

→ **선물을 받아 멤버십을 소지하게 된 경우,**

자의에 의해 가입한 것이 아니라는 점을 고려해

티켓 취소에 대한 디메리트 or 취소하지 않는 것에 대한 더 강력한 메리트가 필요할 것으로 보임

II.취소표 모델 결과 활용

1 취소여부와 멤버십

무료

- 무료회원: 가입비 조건도, 혜택도 없으나 예술의전당 회원으로는 가입되어 있는 사람들
- 다른 멤버십 가입여부 무관, 무료회원에 가입한 사람들 중 **티켓취소 비율은 30% 이상**
- 이들은 주로 예술의 전당 공연이나 전시 예매를 위해 회원가입한 경우가 많으므로,

예술의 전당 공연/전시에 관심이 있는 고객층으로 해석 가능함

- 따라서, 이들을 대상으로 조금 더 적극적인 프로모션을 진행할 필요도, 진행할 효과도 있을 것

Ex. **무료회원이 일회 관람객이 아닌 장기회원으로 남도록 하기 위해,** '첫 공연 티켓 취소 없이 관람하면, 다음 공연(혹은 전시) 당일티켓 구매 기회 제공'과 같은 프로모션 진행

1 취소여부와 멤버십

노블

- 노블회원의 가입 조건: 70세(만나이 X) 이상

→ 고령에도 불구하고 예술의 전당 회원 조건을 알고 가입을 한다

= 공연 및 전시에 매우 깊은 조예가 있거나, 자주 이용한다

- 단, 노블회원이 아닌 경우는 크게 두 가지: 70대 이상이 아니거나, 70대 이상 미가입자

→ 전자의 경우는 고려할 대상이 아니지만, 후자의 경우, 예술의 전당 입장에서 공연 및 아카데미

또는 강좌 활성화의 기회를 놓치는 꼴이 되어버릴 수 있기 때문에, 적극적인 멤버십 홍보 필요

2 취소여부와 장르

전시 & 가족극

- 유일하게 전체 장르 중 **취소 비율이 0%**

→ 가족극: 가족 단위의 관객이 많기 때문에, **가족 모두가 일정 조율을 통해 시간을 내어 미리 예매해 놓은 티켓**일 확률이 높음. 따라서 취소를 쉽게 하지 않는 경향이 있다고 해석 가능

→ 전시: 각종 공연에 비해 상대적으로 **시간적/가격적 부담이 덜하므로,** 크게 취소해야 할 이유가 없다고 해석 가능

2 취소여부와 장르

복합 장르, 교향곡, 클래식, 성악

- 취소 비율이 35% 이상으로, 전체 장르 중 취소율이 가장 높은 장르들

→ 위 장르들에 대한 티켓 취소할 경우 디메리트 or 티켓 취소하지 않을 경우 메리트를 확실하게 주어, 취소 비율을 낮출 방안을 모색할 필요가 있음

→ Why? 누군가가 티켓을 예매했다가 취소하면,
예술의 전당 입장에서는 실제 구매로 이어질 수 있었던
예비 티켓 구매자를 놓친 격이 됨

III. 취소표 모델링 시사점

고객의 특성 이해 + 공연의 특성 이해

어떤 특성을 가진 고객이 티켓 취소를 많이 하는가?
그 이유는 무엇일까?

→ 그렇다면, 그들이 티켓을 취소하지 않도록 유인하려면,
어떤 마케팅 플랜을 도출해야 할까?

공연의 장르는 왜, 어떻게 취소율에 영향을 줄까?
취소하는 사람들에게 직접 묻고자 서베이를 해볼까?

→ 더 나은 인사이트가 나올 수 있는, 추가로 진행하면 좋을 사후 조사 및 분석 아이디어 도출 가능

취소여부 예측

감사합니다